


Evaluación y fine-tuning de modelos visión-lenguaje para la mejora del análisis morfológico en hematología digital.



Universitat Oberta
de Catalunya



UNIVERSITAT DE
BARCELONA

Diana Gutiérrez Martínez

Machine Learning

Máster en Bioinformática
y Bioestadística

Nombre del director/a de TFM:

Edwin Santiago Alférez

Baquero

Nombre del/de la PRA:

Agnès Pérez

Junio 2026



Esta obra está sujeta a una licencia de Reconocimiento
<https://creativecommons.org/licenses/by-nc/3.0/es/>

Dedicatoria

Este TFM representa el esfuerzo, la constancia y todas esas pequeñas batallas silenciosas que, con perseverancia, acaban convirtiéndose en un logro.

"No importa lo lento que vayas, mientras no te detengas." — Confucio

Dedicado a mis padres, a mi hermano y a mi cuñada, por su apoyo incondicional.

A mis yayos, que, aunque no tuvieron la oportunidad de ir a la escuela, aprendieron por sí solos leyendo libros. Ellos me enseñaron el valor del esfuerzo y de nunca dejar de aprender.

A mi amiga Concha, por estar siempre ahí.

A Edwin, mi mentor, por creer en mí y ayudarme a crecer personal y profesionalmente.

Y también a mí misma, porque compaginar trabajo, estudios y vida personal con 39 años, no ha sido fácil, pero nunca dejé de seguir adelante sin tirar la toalla.

A todos vosotros, gracias.

"El éxito no es definitivo, el fracaso no es fatal: lo que cuenta es el coraje para continuar." — Winston Churchill

Ficha del Trabajo Final

Título del trabajo:	Evaluación y <i>fine-tuning</i> de modelos visión-lenguaje para la mejora del análisis morfológico en hematología digital.
Nombre del autor/a:	Diana Gutiérrez Martínez
Nombre del director/a de TF:	Edwin Santiago Alférez Baquero
Nombre del/de la PRA:	Agnès Pérez
Fecha de entrega:	Junio 2026
Titulación o programa:	Máster en Bioinformática y Bioestadística
Área del trabajo final:	Machine Learning
Idioma del trabajo:	Castellano
Palabras clave:	Vision-Language Models (VLMs), Multimodal Learning, Hematology, Blood Cell Morphology, Dataset Validation, Parameter-Efficient Fine-Tuning, Multimodal Evaluation

Resumen del trabajo

Este Trabajo Fin de Máster presenta el desarrollo y validación de un pipeline multimodal para la evaluación y mejora de descripciones automáticas en imágenes de células sanguíneas periféricas, orientado al ajuste fino (*fine-tuning*) de modelos visión-lenguaje (VLM).

Aunque estudios previos han demostrado la utilidad de estos modelos para la clasificación celular y la generación de descripciones, aspectos clave como la fiabilidad, la coherencia descriptiva y la consistencia morfológica de los *datasets* generados automáticamente no han sido evaluados de forma sistemática.

Para abordar esta limitación, se construye un *dataset* multimodal utilizando un modelo Vision Transformer (ViT) para la clasificación y un modelo BLIP para la generación inicial de descripciones. Sobre este *dataset* se aplica un marco de evaluación estructurado basado en referencias morfológicas hematológicas y se desarrolla un pipeline reproducible en Python que integra extracción de características, normalización terminológica y evaluación automática.

Posteriormente, se exploran distintas estrategias para mejorar las descripciones generadas, incluyendo el ajuste fino de BLIP mediante LoRA, un enfoque híbrido de postprocesado lingüístico y el uso de modelos generalistas como Gemma 3 para refinamiento textual. Además, se incorpora Qwen3-VL como modelo multimodal de referencia.

Finalmente, se realiza una evaluación comparativa para analizar el impacto de la auditoría del *dataset* y de las estrategias de refinamiento sobre el rendimiento de los modelos visión-lenguaje. Los resultados muestran mejoras relevantes en precisión morfológica, coherencia descriptiva y fiabilidad global de las descripciones generadas. Como contribución principal, este trabajo propone un marco reproducible para la evaluación multimodal de descripciones en hematología basado en validación estructural, análisis por atributos y evaluación semántica.

Abstract

This Master's Thesis presents a multimodal pipeline for the evaluation, validation, and fine-tuning of vision-language models (VLMs) for automatic description generation in peripheral blood cell images. Despite their potential in cell classification and caption generation, key aspects such as reliability, descriptive consistency, and morphological consistency remain insufficiently explored.

To address this limitation, a multimodal dataset is constructed using a Vision Transformer (ViT) model for classification and a BLIP model for initial caption generation. A structured evaluation framework is then applied, based on the comparison of generated descriptions with structured morphological references derived from expert hematological knowledge. In addition, a reproducible Python pipeline is developed, integrating feature extraction, terminological normalization, and automatic evaluation through semantic and image-text consistency metrics.

Subsequently, different strategies were explored to improve the generated descriptions, including BLIP fine-tuning with LoRA, a hybrid post-processing approach combining morphological control and natural language generation, and the use of a general-purpose model such as Gemma 3 as a semantic and linguistic refinement mechanism. Furthermore, a fine-tuned multimodal model (Qwen3-VL) is incorporated as a reference to contextualize performance within a state-of-the-art setting.

Finally, a comparative evaluation is conducted to analyze the impact of dataset auditing and refinement strategies on the performance of vision-language models. The results show relevant improvements in morphological accuracy, morphological coherence, and the overall reliability of automatically generated descriptions. The main contribution of this work is a reproducible framework for multimodal evaluation in hematology, integrating structural validation, attribute-level analysis, and semantic evaluation.

Índice

Lista de Figuras.....	8
Lista de Tablas.....	9
Capítulo 1.....	10
1. Introducción.....	10
1.1 Contexto y justificación del trabajo.....	10
1.2 Objetivos del trabajo.....	11
1.3 Impacto en sostenibilidad, ético-social y de diversidad.....	12
1.4 Enfoque y método seguido.....	13
1.5 Planificación del trabajo.....	15
1.6 Resultados alcanzados.....	21
1.7 Breve descripción de los otros capítulos de la memoria.....	23
1.8 Declaración sobre el uso de inteligencia artificial generativa.....	24
Capítulo 2.....	25
2. Estado del arte.....	25
2.1 Digitalización y análisis automatizado en hematología.....	25
2.2 <i>Deep learning</i> en imagen médica.....	25
2.3 Vision Transformers (ViT) en imagen médica.....	26
2.4 Modelos visión-lenguaje (VLMs).....	27
2.5 BLIP como modelo de visión-lenguaje.....	29
2.6 Adaptación multimodal mediante <i>fine-tuning</i>	30
2.7 Modelos multimodales de referencia.....	31
2.8 Limitaciones metodológicas en <i>datasets</i> multimodales.....	31
Capítulo 3.....	33
3. Análisis y desarrollo metodológico.....	33
3.1 Descripción del <i>dataset</i> original.....	33
3.2 Análisis exploratorio inicial.....	38
3.3 Definición del esquema estructurado de atributos morfológicos.....	41
3.4 Diseño e implementación del <i>pipeline</i> de validación.....	46
3.5 Arquitectura de reproducibilidad.....	50
3.6 Resumen metodológico.....	51
Capítulo 4.....	54
4. Resultados.....	54
4.1 Resultados del proceso de validación estructural.....	54
4.2 Evaluación semántica mediante modelos de lenguaje.....	58

4.3 Comparativa entre modelos	66
4.4 Comparativa global entre modelos y estrategias de generación	76
Capítulo 5.....	81
5. Discusión	81
Capítulo 6.....	82
6. Valoración económica	82
Capítulo 7.....	83
7. Conclusiones y trabajos futuros.....	83
7.1. Conclusiones.....	83
7.2. Líneas de futuro	83
7.3. Seguimiento de la planificación.....	84
7.4 Impacto ético, social y de sostenibilidad	84
Glosario.....	85
Bibliografía	87
Apéndice	91
Anexo 1. <i>Pipeline</i> completo del sistema.....	91
Anexo 2. Definición formal de métricas e indicadores de evaluación	92
Anexo 3. Prompt de evaluación automática	97

Lista de Figuras

Figura 1. Diagrama de Gantt de la planificación temporal del proyecto. Fuente: Elaboración propia.	18
Figura 2. Arquitectura multimodal de BLIP, basada en un encoder visual, módulos textuales y mecanismos de alineación imagen-texto. Fuente: Adaptado de Li et al. (2022).	29
Figura 3. Distribución de las clases celulares presentes en el dataset utilizado en el estudio. Fuente: Elaboración propia.	39
Figura 4. Pipeline multimodal propuesto para el análisis morfológico en hematología digital. El flujo integra clasificación visual, generación de captions, normalización terminológica, extracción de atributos, fine-tuning, refinamiento textual y auditoría multimodal . Fuente: Elaboración propia.	51
Figura 5. Matriz de confusión normalizada por filas del clasificador ViT sobre las 12 clases celulares. Cada fila representa la distribución porcentual de predicciones para una clase real. Fuente: Elaboración propia. ..	57
Figura 6. Diagrama aluvial de concordancia entre Gemini-3-flash-preview y Qwen2.5-VL en una muestra estratificada de 200 imágenes. Fuente: Elaboración propia.	64
Figura 7. Comparativa del rendimiento de modelos de visión y lenguaje en métricas morfológicas y de auditoría automática. Fuente: Elaboración propia.	72
Figura 8. Heatmap comparativo del rendimiento por atributo morfológico en los modelos evaluados. Fuente: Elaboración propia.	73
Figura 9. Comparativa cualitativa de descripciones generadas por distintos modelos a partir de una misma imagen celular. Fuente: Elaboración propia.	75

Lista de Tablas

Tabla 1. Correspondencia entre objetivos específicos y evidencias verificables. Fuente: Elaboración propia.	12
Tabla 2. Registro de seguimiento y control semanal del proyecto. Fuente: Elaboración propia.	20
Tabla 3. Ejemplo de representación tabular de atributos morfológicos para distintas clases celulares. Fuente: Elaboración propia.	45
Tabla 4. Métricas cuantitativas empleadas para evaluar la calidad estructural y semántica del dataset. Fuente: Elaboración propia.	56
Tabla 5. Distribución porcentual de los tipos de error detectados en las descripciones generadas por BLIP base, BLIP v1 y BLIP v2. Fuente: Elaboración propia.	61
Tabla 6. Comparativa global entre modelos tras evaluación con Gemini-3-flash-preview. Fuente: Elaboración propia.	62
Tabla 7. Resultados en configuración canónica. Fuente: Elaboración propia.	68
Tabla 8. Comparativa global de modelos evaluados mediante métricas descriptivas y morfológicas. Fuente: Elaboración propia.	69
Tabla 9. Accuracy por atributo morfológico en los modelos principales. Fuente: Elaboración propia.	71
Tabla 10. Estimación de costes asociados al desarrollo del proyecto. Fuente: Elaboración propia.	82

Capítulo 1

1. Introducción

1.1 Contexto y justificación del trabajo

El análisis morfológico de células sanguíneas periféricas constituye una herramienta esencial en el diagnóstico hematológico. A pesar de los avances en biología molecular y genómica, la evaluación microscópica sigue siendo un procedimiento clave en la práctica clínica (Bain, 2019). No obstante, la interpretación manual de frotis sanguíneos depende de la experiencia del especialista, lo que introduce variabilidad interobservador e intraobservador y limita la estandarización incluso en entornos especializados (Sasada et al., 2018).

Para reducir esta variabilidad, en los últimos años se han desarrollado sistemas automatizados de clasificación celular y analizadores digitales de morfología, como CellaVision DM 960 o Sysmex DI-60, basados en aprendizaje profundo y redes neuronales convolucionales (CNN), capaces de extraer características morfológicas a partir de imágenes digitales. Aunque estas herramientas han mejorado la consistencia diagnóstica, persisten limitaciones relacionadas con la calidad de los datos y la capacidad de generalización de los modelos (Kim et al., 2025).

Además, estudios multicéntricos han evidenciado variabilidad entre observadores humanos y sistemas automatizados, lo que refuerza la necesidad de marcos metodológicos sólidos y reproducibles (Da Rin et al., 2022).

Paralelamente, la inteligencia artificial ha experimentado un crecimiento significativo en hematología, especialmente desde 2019, con aplicaciones en clasificación celular, análisis morfológico y predicción clínica (Gunes, 2025). Diversos estudios han demostrado que los modelos basados en aprendizaje profundo pueden alcanzar niveles de precisión comparables a los de expertos en tareas de reconocimiento celular (Matek et al., 2019). Más recientemente, los modelos multimodales que integran información visual y textual han ampliado las capacidades de análisis automatizado en el ámbito biomédico (Li et al., 2022).

Sin embargo, la fiabilidad de estos modelos depende de la calidad, estructura y validación de los *datasets* utilizados en su entrenamiento. La falta de estandarización, documentación y control de calidad en *datasets* médicos puede comprometer la reproducibilidad y robustez de los sistemas de inteligencia artificial (Roberts

et al., 2021). En este contexto, resulta necesario desarrollar metodologías orientadas a la validación reproducible y al control sistemático de calidad en *datasets* multimodales.

En consecuencia, este trabajo se centra en la estructuración y validación de un *dataset* multimodal destinado al *fine-tuning* de modelos visión-lenguaje en hematología. Dado que estos modelos aprenden la alineación entre imagen-texto, ambigüedades terminológicas, inconsistencias morfológicas o desalineaciones semánticas pueden afectar a la calidad de las representaciones generadas.

Para contrastar esta hipótesis, se evaluó el impacto de la estructuración del *dataset* mediante *fine-tuning*, comparando el rendimiento entre la versión original y una versión estructurada y auditada. Asimismo, se analizaron estrategias de generación y refinamiento para mejorar la consistencia descriptiva y la precisión morfológica.

1.2 Objetivos del trabajo

1.2.1 Objetivos generales

Establecer un marco de evaluación y *fine-tuning* de Vision-Language Models (VLMs) que permita mejorar la precisión morfológica y la fiabilidad del análisis morfológico automatizado.

1.2.2 Objetivos específicos

OE1. Diseñar un protocolo de evaluación morfológica basado en el estándar de Merino (2020) para la detección de inconsistencias morfológicas y errores descriptivos en *datasets* sintéticos.

OE2. Implementar la transformación automática del texto libre en representaciones estructuradas mediante técnicas de procesamiento del lenguaje natural y normalización terminológica.

OE3. Desarrollar mecanismos automáticos de control de calidad para la detección de inconsistencias estructurales, contradicciones internas y posibles sesgos derivados del desequilibrio en la distribución de clases.

OE4. Aplicar procesos de *fine-tuning* y evaluar estrategias de modelado visión-lenguaje mediante la comparación entre *datasets* no auditados y estructurados, analizando su impacto en la alineación semántica, la precisión morfológica y la adecuación morfológico-descriptiva.

OE5. Garantizar la reproducibilidad y trazabilidad del sistema mediante un pipeline modular, documentación técnica y control de versiones en hematología digital.

1.2.3 Correspondencia entre objetivos específicos y evidencias verificables

Con el fin de reforzar el carácter evaluable de los objetivos específicos, se establece la siguiente correspondencia entre cada objetivo y sus evidencias verificables.

Tabla 1. Correspondencia entre objetivos específicos y evidencias verificables. Fuente: Elaboración propia.

Objetivo específico	Evidencia verificable
OE1. Diseñar un protocolo de evaluación morfológica basado en el estándar de Merino (2020) para la detección de inconsistencias morfológicas y errores descriptivos en <i>datasets</i> sintéticos.	Protocolo metodológico basado en atributos morfológicos y ejemplos de inconsistencias detectadas.
OE2. Implementar la transformación automática del texto libre en representaciones estructuradas mediante técnicas de procesamiento del lenguaje natural y normalización terminológica.	Módulo funcional de procesamiento del lenguaje natural integrado en el <i>pipeline</i> , diccionario terminológico controlado (<i>YAML</i>) y ejemplos documentados de transformación automática de descripciones textuales en atributos estructurados.
OE3. Desarrollar mecanismos automáticos de control de calidad para la detección de inconsistencias estructurales, contradicciones internas y posibles sesgos derivados del desequilibrio en la distribución de clases.	Reglas de validación implementadas e informes de inconsistencias y del balance de clases.
OE4. Aplicar procesos de <i>fine-tuning</i> y evaluar estrategias de modelado visión-lenguaje mediante la comparación entre <i>datasets</i> no auditados y estructurados, analizando su impacto en la alineación semántica, la precisión morfológica y la adecuación morfológico-descriptiva.	Experimentos comparativos entre <i>datasets</i> auditados y no auditados.
OE5. Garantizar la reproducibilidad y trazabilidad del sistema mediante un pipeline modular, documentación técnica y control de versiones en hematología digital.	Repositorio en GitHub, documentación técnica y organización modular del <i>pipeline</i> .

1.3 Impacto en sostenibilidad, ético-social y de diversidad

Desde una perspectiva ética y social, este trabajo promueve la transparencia, trazabilidad y fiabilidad de los

sistemas de inteligencia artificial en el ámbito sanitario. La validación estructural y el control automatizado de calidad mejoran la consistencia de las descripciones morfológicas y facilitan la auditabilidad y la supervisión por parte de los profesionales sanitarios (Ahadian et al., 2026).

En términos de sostenibilidad tecnológica, la estructuración de los datos y la automatización de la validación optimizan recursos computacionales y aumentan la eficiencia del entrenamiento y *fine-tuning* de modelos (Pan & Yang, 2010). Asimismo, el análisis del balance de clases y la detección de sesgos favorecen la equidad y la capacidad de generalización de los modelos (Joseph, 2025).

Por último, la mejora de la coherencia estructural incrementa la interpretabilidad y la transparencia del sistema, mitigando el efecto de “caja negra” en los sistemas de apoyo al análisis morfológico (Abbas et al., 2025). En conjunto, estas aportaciones refuerzan la evaluación rigurosa como elemento clave para desarrollar modelos visión-lenguaje robustos y fiables en hematología digital.

1.4 Enfoque y método seguido

1.4.1. Estrategias consideradas

Para abordar el problema planteado se consideraron dos estrategias metodológicas. La primera consistía en ampliar los experimentos de *fine-tuning*, incorporando nuevas arquitecturas multimodales y optimizando hiperparámetros para mejorar directamente el rendimiento de los modelos visión-lenguaje (Howard & Ruder, 2018; Pan & Yang, 2010).

La segunda estrategia se centraba en reforzar el *dataset* y el flujo experimental desde una perspectiva metodológica, priorizando la validación estructural de los datos, la normalización terminológica y la implementación de mecanismos reproducibles de control de calidad.

Se optó por este segundo enfoque como eje principal del trabajo, al considerar que la calidad y la coherencia del *dataset* constituyen un requisito previo para obtener resultados fiables en modelos multimodales. En este contexto, la evaluación rigurosa de los datos se plantea como un elemento clave para mejorar la alineación semántica y la fiabilidad de las descripciones generadas (Li et al., 2022; Roberts et al., 2021).

De forma complementaria, se incluyen pruebas exploratorias con una arquitectura visión-lenguaje para analizar el impacto de las mejoras estructurales del *dataset* sobre la coherencia morfológica y la calidad descriptiva de

las salidas generadas. Estas pruebas permitieron comparar distintas estrategias de generación, desde representaciones estructuradas basadas en atributos morfológicos hasta enfoques basados en lenguaje natural.

1.4.2 Metodología seleccionada

El trabajo siguió una metodología incremental y reproducible para la auditoría, estructuración y evaluación de un *dataset* multimodal, compuesta por cinco fases: (1) análisis del *dataset* original para identificar inconsistencias y evaluar la coherencia imagen-texto; (2) definición de un esquema formal de atributos morfológicos; (3) desarrollo de un pipeline modular para normalización, extracción, validación y cálculo de métricas; (4) evaluación mediante modelos visión-lenguaje para analizar el impacto de la estructuración; y (5) auditoría multimodal para evaluar la consistencia morfológica y la correspondencia imagen-texto.

El pipeline se articuló en torno a BLIP+LoRA como núcleo de generación morfológica, permitiendo la evaluación de distintas estrategias de generación, desde representaciones canónicas basadas en atributos estructurados hasta enfoques híbridos y libres en lenguaje natural. Asimismo, se incorporó refinamiento semántico mediante Gemma. La evaluación automática utilizó Gemini-3-flash-preview como auditor multimodal principal para analizar la alineación semántica y la correspondencia imagen-texto, mientras que Qwen se empleó con dos finalidades. Qwen3-VL se incorporó como modelo multimodal de referencia en la comparativa final frente a BLIP+LoRA y Gemma 3. Por su parte, Qwen2.5-VL se utilizó como segundo evaluador independiente sobre una muestra estratificada para estimar la concordancia con Gemini y reducir el sesgo asociado al uso de un único auditor automático, actuando como mecanismo adicional de análisis de robustez del proceso de auditoría automática.

1.4.3 Infraestructura técnica para el fine-tuning

Para garantizar la eficiencia y viabilidad computacional del *fine-tuning*, se empleó una arquitectura optimizada basada en técnicas de entrenamiento eficiente e infraestructuras bajo demanda.

El *fine-tuning* se realizó mediante la librería Unsloth, utilizando LoRA (*Low-Rank Adaptation*), como técnica de adaptación eficiente de parámetros, combinada con estrategias de cuantización y optimización de memoria que redujeron el consumo de VRAM y aceleraron el entrenamiento sin comprometer el rendimiento.

Los experimentos se ejecutaron en la plataforma Modal, que proporciona computación en la nube con GPUs *serverless* (H100 y L40S), mejorando la escalabilidad y eliminando la dependencia de infraestructura local. La

gestión de modelos se realizó mediante el ecosistema Hugging Face (*Transformers*), facilitando la integración de arquitecturas preentrenadas y la estandarización del flujo experimental.

Finalmente, los *datasets*, *embeddings* y resultados se almacenaron en Google Cloud Platform (GCP), mientras que el código se versionó en GitHub, garantizando la reproducibilidad, trazabilidad y organización estructurada del *pipeline*.

1.5 Planificación del trabajo

1.5.1 Desglose de tareas

Para alcanzar los objetivos del trabajo, se definieron las siguientes tareas:

- **Tarea 1: Revisión bibliográfica y marco teórico (2 semanas)**

Objetivo: Revisar el estado del arte en hematología digital, validación de *datasets* médicos y modelos visión-lenguaje aplicados a imagen biomédica.

Descripción: Revisión de la literatura sobre análisis morfológico automatizado, calidad y validación de *datasets* multimodales, y aplicaciones de modelos visión-lenguaje en imagen médica. Además, se estudian métricas de evaluación semántica y metodologías de auditoría multimodal.

Subtareas:

- Revisar Los fundamentos de hematología digital y análisis morfológico automatizado.
- Analizar modelos visión-lenguaje aplicados a imagen biomédica.
- Estudiar metodologías de construcción, validación y evaluación de *datasets* multimodales.

Fecha de inicio: 19 de febrero de 2026

Fecha de fin: 4 de marzo de 2026

- **Tarea 2: Análisis y rediseño estructural del *dataset* (3 semanas)**

Objetivo: Analizar, estructurar y validar el *dataset* multimodal original para mejorar su coherencia morfológica y consistencia descriptiva.

Descripción: Evaluación del *dataset* para detectar inconsistencias estructurales, ambigüedades terminológicas, desbalance de clases e incoherencias imagen-texto. A partir de ello, se define un esquema de atributos morfológicos que permitió transformar texto libre en representaciones estructuradas y facilitar su validación automática.

Subtareas:

- Analizar la estructura y calidad del *dataset* multimodal.
- Identificar inconsistencias estructurales, terminológicas y de alineación imagen-texto.
- Definir atributos morfológicos estructurados y sus reglas de validación.
- Diseñar la representación estructurada para su integración en el pipeline.

Fecha de inicio: 5 de marzo de 2026

Fecha de fin: 19 de marzo de 2026

● **Tarea 3: Desarrollo del *pipeline* de auditoría morfológica y refinamiento textual (4 semanas)**

Objetivo: Implementar un *pipeline* modular de auditoría y validación del *dataset* multimodal en Python.

Descripción: Desarrollo de un sistema reproducible que integra normalización terminológica, extracción automática de atributos morfológicos, validación basada en reglas morfológicas y evaluación mediante métricas estructurales, métricas de similitud semántica y modelos multimodales. Como resultado, se obtiene un *dataset* auditado y refinado para el *fine-tuning* de modelos visión-lenguaje.

Subtareas:

- Implementar normalización terminológica y extracción de atributos morfológicos.
- Desarrollar mecanismos de validación estructural y evaluación semántica.
- Generar informes automatizados y realizar auditoría del dataset.

Fecha de inicio: 20 de marzo de 2026

Fecha de fin: 17 de abril de 2026

● **Tarea 4: Generación morfológica, *fine-tuning* y refinamiento textual (2 semanas)**

Objetivo: Implementar un modelo visión-lenguaje basado en BLIP+LoRA para la generación morfológica y evaluar el impacto del refinamiento textual mediante modelos de lenguaje ajustados de forma eficiente.

Descripción: Se emplea un modelo visión-lenguaje basado en BLIP+LoRA para la generación de descripciones morfológicas. Se analiza el impacto de la validación estructural del *dataset* sobre la coherencia morfológica y la alineación semántica, y se aplican técnicas de refinamiento textual mediante modelos de lenguaje (p. ej., Gemma) ajustados con Unsloth y LoRA. Esta fase permite evaluar de forma exploratoria el efecto combinado de la calidad del *dataset* y del refinamiento sobre las salidas generadas.

Subtareas:

- Ajustar BLIP+LoRA para la generación de descripciones morfológicas.
- Generar descripciones utilizando el *dataset* original y el *dataset* validado.
- Aplicar técnicas de refinamiento textual mediante modelos de lenguaje.
- Evaluar la calidad estructural, semántica y descriptiva de las salidas generadas.

Fecha de inicio: 18 de abril de 2026

Fecha de fin: 2 de mayo de 2026

● **Tarea 5: Análisis de resultados, evaluación y métricas (2 semanas)**

Objetivo: Evaluar de forma cuantitativa y cualitativa el rendimiento del sistema, analizando el impacto de la validación del *dataset*, BLIP+LoRA y el refinamiento textual en la coherencia estructural, semántica y morfológica.

Descripción: Análisis mediante métricas estructurales, métricas NLP y auditoría automatizada multimodal. Se comparan configuraciones (*dataset* original vs. validado, antes vs. después del refinamiento) incluyendo Qwen3-VL como modelo de referencia (*benchmark*). Asimismo, se evalúa la coherencia a nivel de atributos morfológicos.

Subtareas:

- Analizar el impacto de la validación sobre la calidad del *dataset*.
- Evaluar las descripciones mediante métricas estructurales y semánticas.
- Comparar el rendimiento de los modelos evaluados.
- Analizar la coherencia morfológica y la reproducibilidad de los resultados.

Fecha de inicio: 3 de mayo de 2026

Fecha de fin: 17 de mayo de 2026

● Tarea 6: Redacción final, documentación y entrega (3 semanas)

Objetivo: Elaborar la memoria final del trabajo, documentando de forma estructurada la metodología, los resultados y el *pipeline* desarrollado, garantizando la claridad, reproducibilidad y calidad académica del proyecto.

Descripción: Redacción del informe final integrando metodología, *pipeline*, evaluación y resultados, junto con la preparación de figuras y documentación técnica. Se organiza el repositorio para garantizar la reproducibilidad y se prepara el material para la defensa.

Subtareas:

- Redactar la memoria final e integrar los resultados obtenidos.
- Elaborar figuras, diagramas y documentación técnica.
- Organizar el repositorio y los materiales de reproducibilidad.
- Preparar la defensa y realizar la revisión final del trabajo.

Fecha de inicio: 18 de mayo de 2026

Fecha de fin: 10 de junio de 2026

1.5.2 Diagrama de Gantt

La planificación temporal del proyecto se diseñó para una duración aproximada de cuatro meses, organizando las tareas de forma secuencial y progresiva. Se prioriza el análisis y la estructuración del *dataset*, seguido del desarrollo del *pipeline* de auditoría automática basada en criterios morfológicos y, finalmente, la evaluación del sistema mediante generación morfológica, métricas y técnicas de refinamiento textual.




Figura 1. Diagrama de Gantt de la planificación temporal del proyecto. Fuente: Elaboración propia.

1.5.3 Principales Hitos (Milestones)

Los principales hitos del trabajo son:

- **Hito 1:** Revisión bibliográfica y marco teórico (4 de marzo de 2026).
- **Hito 2:** Definición y estructuración del *dataset* multimodal (19 de marzo de 2026).
- **Hito 3:** Desarrollo del *pipeline* de validación estructural y auditoría multimodal (17 de abril de 2026).
- **Hito 4:** Implementación de modelos visión-lenguaje (BLIP+LoRA, Gemma y Qwen3-VL) y refinamiento semántico (2 de mayo de 2026).
- **Hito 5:** Evaluación multimodal y análisis comparativo del sistema (17 de mayo de 2026).
- **Hito 6:** Redacción final y entrega del TFM (10 de junio de 2026).

1.5.4 Análisis de riesgos

El desarrollo del trabajo implica diversos riesgos técnicos, metodológicos y organizativos que podrían afectar al cumplimiento del cronograma o a la calidad de los resultados. A continuación, se describen los principales riesgos identificados junto con sus estrategias de mitigación:

Riesgo 1: Inconsistencias en el *dataset* original

Descripción: El *dataset* puede contener ambigüedades terminológicas, inconsistencias en los atributos morfológicos o errores estructurales que dificulten su normalización y validación.

Impacto: Retrasos en la estructuración y validación del *dataset*.

Mitigación: Definir un esquema mínimo viable de atributos morfológicos, priorizar las validaciones estructurales y documentar de forma explícita las decisiones de corrección, exclusión o simplificación.

Riesgo 2: Complejidad en la extracción automática de características textuales

Descripción: Alta variabilidad lingüística en las descripciones morfológicas.

Impacto: Reducción de la precisión y consistencia del *pipeline* de estructuración.

Mitigación: Utilizar diccionarios controlados, *embeddings* y validación sobre subconjuntos representativos.

Riesgo 3: Limitaciones computacionales

Descripción: Elevado consumo de recursos durante entrenamiento y evaluación.

Impacto: Restricción del alcance experimental o reducción del número de pruebas exploratorias.

Mitigación: Aplicar *fine-tuning* eficiente y utilizar GPUs *serverless*.

Riesgo 4: Desviaciones en la planificación temporal

Descripción: Posibles retrasos en tareas críticas del desarrollo y evaluación.

Impacto: Menor tiempo para análisis y redacción final.

Mitigación: Priorizar hitos críticos y realizar seguimiento semanal.

Riesgo 5: Baja mejora observable tras la validación y las estrategias de refinamiento

Descripción: Las mejoras del *dataset* y del refinamiento textual pueden no reflejarse claramente en las métricas del modelo.

Impacto: Dificultad para evidenciar el impacto del enfoque metodológico.

Mitigación: Complementar la evaluación con métricas estructurales, análisis cualitativo y evaluación por atributos morfológicos, además de comparativas entre versiones del sistema.

1.5.5 Seguimiento y control del proyecto

El seguimiento del proyecto se realizó mediante revisiones semanales del progreso y del cumplimiento de los hitos establecidos. Ante posibles desviaciones o retrasos, se priorizaron las fases críticas y se reajustó la planificación cuando fue necesario.

Tabla 2. Registro de seguimiento y control semanal del proyecto. Fuente: Elaboración propia.

Sem.	Periodo	Tarea activa	% de dedicación estimada
1	19 Feb - 25 Feb	Revisión bibliográfica.	100%
2	26 Feb - 4 Mar	Revisión bibliográfica.	100%
3	5 Mar - 11 Mar	Análisis y rediseño estructural del <i>dataset</i> .	100%
4	12 Mar - 19 Mar	Análisis y rediseño estructural del <i>dataset</i> .	100%
5	20 Mar - 27 Mar	Desarrollo del <i>pipeline</i> de auditoría automática basada en criterios morfológicos y refinamiento semántico.	100%
6	28 Mar - 3 Abr	Desarrollo del <i>pipeline</i> de auditoría automática basada en criterios morfológicos y refinamiento semántico.	100%
7	4 Abr - 10 Abr	Desarrollo del <i>pipeline</i> de auditoría automática basada en criterios morfológicos y refinamiento semántico.	100%

8	11 Abr - 17 Abr	Desarrollo del <i>pipeline</i> de auditoría automática basada en criterios morfológicos y refinamiento semántico.	100%
9	18 Abr - 24 Abr	<i>Fine-tuning</i> y refinamiento textual mediante modelos de lenguaje.	100%
10	25 Abr - 2 May	<i>Fine-tuning</i> y refinamiento textual mediante modelos de lenguaje.	100%
11	3 May - 10 May	Análisis de resultados y métricas.	100%
12	11 May - 17 May	Análisis de resultados y métricas.	100%
13	18 May - 24 May	Redacción final.	100%
14	25 May - 31 May	Redacción final.	100%
15	1 Jun - 10 Jun	Redacción final.	50%

1.6 Resultados alcanzados

El presente trabajo tuvo como finalidad principal la mejora metodológica y estructural de un *dataset* multimodal orientado al *fine-tuning* de modelos visión-lenguaje en hematología. En coherencia con los objetivos planteados, se obtuvieron los siguientes resultados:

1.6.1 Dataset multimodal estructurado y validado

Se obtuvo una versión estructurada y validada del *dataset* original, capaz de generar descripciones morfológicas más claras, coherentes y cercanas al lenguaje utilizado por especialistas en hematología. Aunque en una fase preliminar se trabajó con 17.092 imágenes procedentes del conjunto original, tras el proceso de auditoría, validación estructural y control de calidad se obtuvo una versión final de 16.503 registros válidos, utilizada como base para las fases posteriores del *pipeline*. Esta reducción respondió a criterios metodológicos orientados a priorizar la calidad y consistencia del conjunto de datos sobre el volumen total de muestras disponibles.

El *dataset* incorporó atributos morfológicos estructurados, normalización terminológica y una representación interoperable en formato JSON o tabular, permitiendo generar descripciones más coherentes, interpretables y morfológicamente consistentes de las imágenes hematológicas.

1.6.2 Pipeline reproducible

Se desarrolló un *pipeline* modular y reproducible orientado al análisis morfológico en hematología, integrando procesamiento del lenguaje natural, normalización terminológica, validaciones basadas en reglas morfológicas y cálculo automatizado de métricas estructurales y semánticas.

El sistema organizó automáticamente los resultados por modelo (ViT, BLIP, BLIP+LoRA, Gemma y Qwen3-VL), incluyendo *datasets*, predicciones, métricas, figuras y configuraciones de los experimentos.

Además, el *pipeline* fue diseñado bajo criterios de reproducibilidad, trazabilidad y organización modular, facilitando su reutilización en futuros estudios y la obtención de descripciones morfológicas más coherentes e interpretables de las imágenes hematológicas.

Con el objetivo de garantizar la transparencia y trazabilidad del trabajo, el código y los principales resultados se encuentran disponibles en:

Repositorio disponible en: <https://github.com/Diana-Gu/blood-cell-vl>

1.6.3 Métricas cuantitativas de calidad

Se obtuvieron indicadores objetivos para evaluar la calidad del *dataset* y de las descripciones generadas, incluyendo la cobertura de atributos morfológicos relevantes, la detección de inconsistencias estructurales y semánticas, métricas de similitud basadas en *embeddings* (BERTScore y CLIPScore), métricas NLP estándar (BLEU, ROUGE y METEOR) y el análisis del balance de clases. Las definiciones y formulaciones completas de las métricas empleadas se recogen en el **Anexo 2**.

Estas métricas permitieron cuantificar el impacto de la validación estructural y del refinamiento semántico sobre la calidad del *dataset* y de las descripciones generadas.

1.6.4 Reportes automáticos del dataset

El *pipeline* generó informes estructurados orientados al análisis y validación del dataset. Estos informes incluían la identificación de inconsistencias morfológicas, errores estructurales y descripciones ambiguas, como atributos incompatibles con la clase celular asignada o discrepancias entre la imagen y el texto. Asimismo, incorporaban análisis de sesgos y de la distribución de las clases celulares, resúmenes estadísticos del estado del dataset tras cada fase de validación y comparativas entre las versiones original y refinada, permitiendo cuantificar el impacto de las modificaciones realizadas. Estos informes facilitaron la trazabilidad,

reproducibilidad y revisión sistemática del *dataset*.

1.6.5 Evaluación exploratoria mediante fine-tuning de un modelo visión-lenguaje open-source

Como validación empírica, se realizó un análisis preliminar del impacto de la mejora estructural del *dataset* sobre las salidas de modelos visión-lenguaje *open-source*.

En una primera fase, se utilizaron ViT y BLIP+LoRA para la generación de descripciones morfológicas a partir de imágenes hematológicas. Posteriormente, las descripciones fueron refinadas mediante modelos de lenguaje como Gemma y evaluadas con modelos multimodales como Gemini-3-flash-preview y Qwen3-VL.

Se analizaron distintas estrategias de generación. En esta fase se compararon un enfoque canónico, basado en representaciones estructuradas de atributos morfológicos explícitos, y un enfoque híbrido, orientado a combinar el control morfológico y la consistencia estructural con un lenguaje más natural y próximo al utilizado en la práctica clínica. La comparación entre ambos permitió evaluar el efecto del grado de estructuración sobre la calidad, coherencia e interpretabilidad de las descripciones generadas.

La evaluación se centró en analizar la coherencia estructural y semántica de las descripciones generadas, la consistencia imagen-texto, la precisión de los atributos morfológicos y las diferencias entre estrategias de generación y refinamiento textual.

1.6.6 Contribución metodológica

Más allá de los resultados técnicos, este trabajo aporta un marco reproducible para la validación estructural y semántica de *datasets* multimodales en el ámbito médico. Asimismo, propone un enfoque centrado en la calidad del dato como elemento fundamental para el entrenamiento y la evaluación de modelos de inteligencia artificial, e ilustra la integración de técnicas de estructuración de datos, evaluación multimodal y refinamiento textual en un contexto de hematología digital.

1.7 Breve descripción de los otros capítulos de la memoria

La presente memoria se estructura en los siguientes capítulos:

✓ **Capítulo 2 (Estado del arte):** Revisión de los fundamentos teóricos y tecnológicos relacionados con la

hematología digital, el aprendizaje profundo y los modelos visión-lenguaje.

✓ **Capítulo 3 (Análisis y desarrollo metodológico):** Descripción del *dataset*, de la metodología propuesta y del pipeline multimodal desarrollado.

✓ **Capítulo 4 (Resultados):** Presentación y análisis de los resultados obtenidos durante la evaluación del sistema.

✓ **Capítulo 5 (Discusión):** Interpretación crítica de los resultados y análisis de las principales limitaciones del estudio.

✓ **Capítulo 6 (Valoración económica):** Estimación de los recursos empleados en el desarrollo del proyecto.

✓ **Capítulo 7 (Conclusiones y trabajos futuros):** Síntesis de las aportaciones principales y líneas futuras de investigación.

Finalmente, la memoria incluye el glosario, la bibliografía y los anexos, que recogen información complementaria para facilitar la comprensión y reproducibilidad del trabajo.

1.8 Declaración sobre el uso de inteligencia artificial generativa

Durante el desarrollo de este Trabajo Final se utilizaron herramientas de inteligencia artificial generativa como apoyo en la organización, estructuración y revisión lingüística del contenido.

Las decisiones metodológicas, la implementación, la experimentación, el análisis de resultados y la validación final fueron realizados íntegramente por la autora. El contenido generado con estas herramientas fue revisado críticamente, adaptado al contexto del trabajo y contrastado con bibliografía académica. En ningún caso se emplearon para generar resultados ni sustituir el razonamiento científico.

La responsabilidad intelectual y científica del trabajo recayó exclusivamente en la autora, y el uso de estas herramientas se realizó conforme a las directrices establecidas por la dirección del Trabajo Final.

Capítulo 2

2. Estado del arte

2.1 Digitalización y análisis automatizado en hematología

El análisis morfológico de células sanguíneas periféricas constituye una herramienta fundamental para el diagnóstico hematológico, permitiendo identificar alteraciones asociadas a patologías como anemias, infecciones, síndromes mielodisplásicos y leucemias (Bain, 2019). Tradicionalmente, este proceso se basa en la observación manual de frotis sanguíneos por especialistas, lo que introduce dependencia del criterio experto y variabilidad interobservador e intraobservador (Sasada et al., 2018).

La digitalización de imágenes microscópicas ha impulsado el desarrollo de sistemas automatizados capaces de analizar grandes volúmenes de datos visuales de forma rápida y estandarizada. Sin embargo, la interpretación morfológica continúa siendo un desafío debido a la complejidad y variabilidad de las células sanguíneas.

En este contexto, la inteligencia artificial ha abierto nuevas posibilidades para el análisis automatizado en hematología, especialmente mediante técnicas de aprendizaje profundo aplicadas a imagen biomédica (Gunes, 2025). No obstante, la fiabilidad de estos sistemas depende tanto de las arquitecturas empleadas como de la calidad del *dataset*, la coherencia de las anotaciones y los procedimientos de validación, lo que evidencia la necesidad de enfoques robustos, reproducibles y consistentes para el desarrollo de modelos aplicados al ámbito hematológico (Litjens et al., 2017; Roberts et al., 2021).

2.2 *Deep learning* en imagen médica

El aprendizaje profundo (*deep learning*) ha transformado el análisis de imagen médica al permitir el aprendizaje automático de representaciones visuales complejas directamente a partir de los datos (LeCun et al., 2015).

A diferencia de los enfoques tradicionales basados en la extracción manual de características, estos modelos aprenden patrones discriminativos mediante entrenamiento *end-to-end*. Entre las arquitecturas más utilizadas destacan las redes neuronales convolucionales (CNN), que han demostrado un alto rendimiento en tareas de

clasificación y segmentación (Litjens et al., 2017), permitiendo construir representaciones jerárquicas desde características de bajo nivel hasta estructuras más abstractas.

No obstante, el rendimiento de estos modelos depende en gran medida de la calidad del *dataset*, el equilibrio entre clases y la disponibilidad de datos anotados. En entornos biomédicos, donde los datos suelen ser limitados y altamente especializados, técnicas como el *transfer learning* y el *fine-tuning* resultan fundamentales para adaptar modelos preentrenados a dominios específicos (Pan & Yang, 2010).

2.2.1 Limitaciones de las CNN

A pesar de su eficacia, las CNN presentan limitaciones inherentes a su diseño, ya que se basan principalmente en la extracción de características locales mediante filtros convolucionales (Krizhevsky et al., 2012), lo que puede dificultar la identificación de relaciones espaciales globales entre distintas regiones de la imagen. En aplicaciones como la hematología, donde la interpretación morfológica depende de patrones celulares complejos y relaciones espaciales sutiles, esta limitación puede afectar a la capacidad de generalización del modelo. Estas restricciones impulsaron el desarrollo de arquitecturas alternativas, como los Transformers, capaces de modelar dependencias globales de forma más eficiente y mejorar la representación contextual de la información visual (Vaswani et al., 2017).

Desde un punto de vista conceptual, los Transformers procesan la información como una secuencia de elementos y utilizan mecanismos de autoatención para estimar qué partes de la entrada son más relevantes entre sí. A diferencia de una convolución local, la autoatención permite relacionar regiones distantes de la entrada y modelar dependencias globales, lo que resulta especialmente útil cuando la interpretación depende de patrones distribuidos en la imagen (Vaswani et al., 2017).

2.3 Vision Transformers (ViT) en imagen médica

Los *Vision Transformers* (ViT) representan un cambio de paradigma en visión por computador al aplicar mecanismos de autoatención al procesamiento de imágenes (Dosovitskiy et al., 2021). A diferencia de las CNN, las imágenes se dividen en parches tratados como secuencias, permitiendo modelar relaciones globales entre distintas regiones de la imagen.

En un Vision Transformer, la imagen se divide en pequeños parches que se proyectan a vectores o embeddings. Estos vectores se combinan con información posicional para conservar la organización espacial de la imagen

y se procesan mediante capas de autoatención. En hematología digital, este enfoque puede facilitar la captura de características como forma nuclear, distribución de cromatina, granulación o relación núcleo/citoplasma.

Este enfoque permite capturar dependencias globales, modelar mejor el contexto visual y generar representaciones más flexibles de la imagen.

En el ámbito de la imagen médica, los *Vision Transformers* han demostrado un rendimiento competitivo en tareas de clasificación y análisis visual, especialmente en escenarios donde la interpretación contextual resulta crítica (Hatamizadeh et al., 2022).

Los modelos ViT pueden emplearse como base para la clasificación de células sanguíneas, proporcionando representaciones semánticas de alto nivel utilizadas posteriormente en el análisis multimodal.

2.4 Modelos visión-lenguaje (VLMs)

Los modelos visión-lenguaje integran información visual y textual dentro de un mismo marco de aprendizaje, generando representaciones conjuntas capaces de modelar relaciones semánticas entre ambas modalidades (Radford et al., 2021).

Estos modelos proyectan imágenes y texto en un espacio latente compartido y optimizan su alineación mediante funciones de pérdida contrastivas, permitiendo abordar tareas multimodales como generación de descripciones, recuperación imagen-texto y razonamiento visual.

En el ámbito biomédico, esta capacidad resulta especialmente relevante, ya que las imágenes médicas suelen ir acompañadas de informes descriptivos y hallazgos morfológicos. Sin embargo, garantizar la coherencia semántica entre ambas modalidades continúa siendo uno de los principales desafíos en el desarrollo de sistemas multimodales aplicados a medicina.

2.4.1 Image captioning como tarea multimodal

El *image captioning* constituye una de las tareas más representativas dentro del aprendizaje multimodal, ya que combina comprensión visual y generación de lenguaje natural para producir descripciones textuales a partir del contenido de una imagen (Vinyals et al., 2015).

A diferencia de tareas más específicas, como la clasificación o la detección de objetos, el *captioning* requiere integrar información visual compleja con mecanismos de generación lingüística consistente y contextualizada. Para ello, el modelo debe identificar estructuras relevantes, interpretar relaciones espaciales y morfológicas entre los elementos presentes en la imagen y generar descripciones semánticamente consistentes.

En el ámbito biomédico, esta tarea adquiere especial relevancia debido a la necesidad de transformar información visual altamente especializada en descripciones morfológicas comprensibles e interpretables.

Como consecuencia, el *image captioning* se ha consolidado como un problema clave en el desarrollo de modelos visión-lenguaje aplicados a imagen médica y análisis automatizado.

2.4.2 Evolución del *captioning*: de CNN + RNN a VLMs

Los primeros modelos de *image captioning* combinaban redes neuronales convolucionales (CNN) para la extracción de características visuales con redes recurrentes (RNN o LSTM) encargadas de la generación secuencial del texto (Karpathy & Fei-Fei, 2015; Vinyals et al., 2015). Este enfoque permitió avances significativos en la generación automática de descripciones, estableciendo las bases iniciales del aprendizaje multimodal.

Sin embargo, estas arquitecturas presentaban limitaciones relacionadas con el modelado del contexto global, la coherencia lingüística y la capacidad de generalización, especialmente en escenarios complejos y dominios especializados como la imagen biomédica.

La incorporación de arquitecturas basadas en *Transformers* supuso un cambio de paradigma al permitir el procesamiento conjunto de información visual y textual mediante mecanismos de autoatención. Esto favoreció una alineación semántica más precisa entre ambas modalidades y permitió el desarrollo de modelos visión-lenguaje más robustos, flexibles y contextualizados.

2.4.3 Modelos de lenguaje y modelos multimodales de gran escala

Los modelos de lenguaje de gran escala o *Large Language Models* (LLMs) son arquitecturas basadas mayoritariamente en Transformers, entrenadas sobre grandes corpus textuales para modelar dependencias lingüísticas, generar texto y realizar tareas de razonamiento, resumen, reformulación o extracción de información (Vaswani et al., 2017; Brown et al., 2020). En este trabajo, los LLMs se utilizan principalmente como mecanismos de refinamiento textual y normalización semántica, no como sustitutos del análisis

morfológico experto.

De forma complementaria, los modelos multimodales de gran escala, también denominados *Vision-Language Large Models* (VLMs) o *Multimodal Large Language Models* (MLLMs), extienden estas capacidades al integrar entradas visuales y textuales. Estos modelos permiten analizar la correspondencia entre imagen y descripción, generar respuestas condicionadas por información visual y evaluar la coherencia imagen-texto. En el contexto de este TFM, Gemini-3-flash-preview se emplea como auditor automático multimodal, Qwen3-VL como modelo visión-lenguaje de referencia y Gemma 3 como modelo de refinamiento textual y multimodal ligero. Esta distinción es importante porque cada modelo cumple una función diferente dentro del pipeline: generación, refinamiento, comparación o auditoría (Gemma Team, 2025; Bai et al., 2025; Google AI for Developers, 2026).

2.5 BLIP como modelo de visión-lenguaje

BLIP (*Bootstrapping Language-Image Pretraining*) es un modelo visión-lenguaje diseñado para integrar comprensión visual y generación de lenguaje dentro de una arquitectura unificada (Li et al., 2022).




Figura 2. Arquitectura multimodal de BLIP, basada en un encoder visual, módulos textuales y mecanismos de alineación imagen-texto. Fuente: Adaptado de Li et al. (2022).

En BLIP, la imagen se codifica mediante un encoder visual, habitualmente basado en ViT, mientras que el texto se procesa mediante módulos de lenguaje que permiten tanto comprender como generar descripciones. La arquitectura combina objetivos de alineación imagen-texto, verificación de correspondencia y modelado de lenguaje. De este modo, el modelo aprende no solo a representar imágenes y textos en un espacio compartido, sino también a generar *captions* condicionadas por la información visual.

Como se observa en la **Figura 2**, BLIP integra un encoder visual basado en Vision Transformer, un encoder textual y un módulo de fusión multimodal mediante mecanismos de cross-attention. Esta arquitectura permite optimizar de forma conjunta diferentes tareas multimodales, incluyendo la alineación imagen-texto (Image-Text Contrastive, ITC), la verificación de correspondencia entre ambas modalidades (Image-Text Matching, ITM) y la generación de lenguaje natural a partir de información visual (Language Modeling, LM).

Además, BLIP incorpora estrategias de bootstrapping que mejoran el proceso de entrenamiento mediante la generación automática de descripciones sintéticas. Estas descripciones se utilizan para complementar y depurar los datos disponibles, reduciendo el impacto del ruido presente en grandes conjuntos de datos multimodales y favoreciendo una mejor alineación entre imágenes y texto. Gracias a estas capacidades, BLIP se ha consolidado como una de las arquitecturas de referencia para tareas de image captioning y análisis multimodal, incluyendo aplicaciones en el ámbito de la imagen médica.

2.5.1 Limitaciones de BLIP en el dominio biomédico

A pesar de sus capacidades multimodales, BLIP es un modelo generalista entrenado principalmente con datos de propósito general. Como consecuencia, su aplicación en contextos biomédicos puede generar descripciones demasiado genéricas, poco específicas desde el punto de vista clínico o insuficientemente alineadas con la morfología celular observada.

Estas limitaciones resultan especialmente relevantes en hematología, donde pequeñas variaciones morfológicas pueden tener implicaciones diagnósticas importantes. Además, la presencia de ambigüedades semánticas o inconsistencias entre imagen-texto puede afectar a la calidad descriptiva de los textos generados.

Por ello, resulta necesario aplicar estrategias de adaptación al dominio biomédico, como el *fine-tuning*, la estructuración del *dataset* y el refinamiento semántico de las descripciones, con el objetivo de mejorar la coherencia morfológica y la precisión descriptiva de las salidas generadas por el modelo.

2.6 Adaptación multimodal mediante *fine-tuning*

El *fine-tuning* de modelos preentrenados constituye una estrategia clave para adaptar arquitecturas multimodales al dominio hematológico (Howard & Ruder, 2018; Pan & Yang, 2010). Arquitecturas como BLIP+LoRA pueden

emplearse para generar descripciones morfológicas a partir de imágenes microscópicas (Unsloth AI, 2024).

Estos enfoques pueden integrar normalización terminológica, extracción estructurada de atributos morfológicos y validación basada en reglas morfológicas, permitiendo mejorar la coherencia semántica y morfológica de las salidas textuales.

Posteriormente, el corpus generado puede utilizarse para el refinamiento textual mediante modelos de lenguaje como Gemma, aplicando técnicas eficientes basadas en LoRA y Unsloth. Este proceso puede mejorar la fluidez lingüística sin alterar la base morfológica de las descripciones.

Finalmente, modelos multimodales como Qwen3-VL pueden utilizarse como referencia para contextualizar el rendimiento del sistema y comparar distintas estrategias de generación hematológica.

2.7 Modelos multimodales de referencia

Los modelos multimodales de gran escala presentan capacidades avanzadas en tareas de comprensión y generación conjunta de información visual y textual, permitiendo analizar relaciones semánticas complejas entre imágenes y lenguaje natural.

Modelos como Gemini-3-flash-preview pueden emplearse como mecanismos de auditoría multimodal para evaluar la consistencia morfológica y semántica entre imágenes hematológicas y descripciones generadas, permitiendo detectar inconsistencias y posibles alucinaciones semánticas.

De forma complementaria, arquitecturas como Qwen3-VL pueden utilizarse como modelos de referencia para comparar distintas estrategias de generación y contextualizar el rendimiento de los sistemas multimodales en términos de coherencia estructural y alineación imagen-texto.

2.8 Limitaciones metodológicas en *datasets* multimodales

Los *datasets* multimodales aplicados al ámbito médico presentan diversos desafíos metodológicos que pueden afectar significativamente al rendimiento y la capacidad de generalización de los modelos visión-lenguaje.

Entre las principales limitaciones identificadas se encontraron el desbalance en la distribución de clases, la variabilidad en la calidad y resolución de las imágenes, las inconsistencias terminológicas en las descripciones morfológicas y las desalineaciones semánticas entre imagen y texto.

Estos factores pueden introducir ruido en el proceso de aprendizaje, dificultar la coherencia de las representaciones multimodales y comprometer la fiabilidad de las descripciones generadas (Li et al., 2022; Roberts et al., 2021).

En este contexto, resulta fundamental desarrollar metodologías orientadas a la normalización semántica, la validación estructurada y el control sistemático de calidad de los datos, con el objetivo de mejorar su consistencia interna, reproducibilidad y utilidad en el entrenamiento de modelos visión-lenguaje aplicados a imagen médica (Hasanzadeh et al., 2025; Roberts et al., 2021).

Capítulo 3

3. Análisis y desarrollo metodológico

3.1 Descripción del *dataset* original

El *dataset* utilizado en este trabajo partió inicialmente de un total de 17.092 imágenes de células sanguíneas periféricas procedentes del *dataset* de Acevedo (Acevedo et al., 2020). Estas imágenes constituyeron la base visual del proyecto y se emplearon para construir un recurso multimodal orientado al análisis morfológico y la evaluación de modelos visión-lenguaje.

Tras el proceso de auditoría, validación estructural y control de calidad desarrollado en este trabajo, se identificaron registros con inconsistencias terminológicas, problemas de alineación imagen-texto y errores estructurales que podían afectar a la calidad del entrenamiento y evaluación de los modelos multimodales. Como consecuencia, dichas muestras fueron excluidas siguiendo criterios metodológicos orientados a priorizar la calidad y robustez del conjunto de datos frente al volumen total de instancias disponibles.

Como resultado de este proceso, la versión final utilizada en los experimentos quedó compuesta por 16.503 imágenes válidas, constituyendo la base empleada en las etapas posteriores de estructuración, *fine-tuning* y evaluación multimodal. Las exclusiones se documentaron como parte del proceso de control de calidad, con el objetivo de preservar la trazabilidad entre imagen, etiqueta y descripción asociada.

A partir de los nombres de archivo se reconstruyó la taxonomía celular, asignando subclases como *eosinophil*, *lymphocyte*, *monocyte*, *band*, *segmented*, *promyelocyte*, *myelocyte*, *metamyelocyte* y *platelet*, entre otras. Posteriormente, el *dataset* se dividió en entrenamiento, validación y test mediante muestreo estratificado para mantener una distribución representativa de las clases celulares.

El componente visual del pipeline se apoyó inicialmente en un modelo Vision Transformer (ViT) utilizado para la clasificación celular. Sobre esta base, BLIP se empleó para generar descripciones automáticas (*captions*) a partir de las imágenes, permitiendo analizar la correspondencia entre la información visual y representación textual.

Sin embargo, las salidas textuales generadas presentaron limitaciones propias de modelos generalistas,

incluyendo falta de especificidad morfológica, descripciones genéricas y pérdida de atributos morfológicamente relevantes. Por ello, el *dataset* se sometió a un proceso progresivo de normalización, enriquecimiento y validación estructural.

Para reforzar la consistencia morfológica del recurso, se incorporaron vocabularios controlados y conocimiento experto en forma de atributos morfológicos y valores permitidos. Esto permitió transformar texto libre en representaciones estructuradas y construir versiones refinadas del *dataset* destinadas al *fine-tuning* y evaluación de modelos BLIP+LoRA.

Como resultado, el *dataset* final integró imágenes, etiquetas celulares, predicciones visuales, descripciones automáticas, atributos morfológicos estructurados y versiones refinadas de *captions*, constituyendo la base experimental para el análisis multimodal desarrollado en este trabajo.

3.1.1 Estructura organizativa del dataset

El *dataset* desarrollado presentó una estructura mixta que combinó una organización jerárquica de imágenes con una representación tabular orientada al análisis multimodal y la trazabilidad del *pipeline*.

Por un lado, las imágenes se almacenaron en directorios organizados por clases celulares, facilitando su utilización en tareas de clasificación supervisada. Esta organización permitió mantener una correspondencia directa entre las carpetas y las etiquetas celulares asociadas.

Por otro lado, se construyó un *dataset* en formato tabular (CSV) en el que cada fila representó una instancia individual asociada a una imagen. Esta estructura permitió integrar información visual, predicciones de modelos, descripciones textuales procesadas y refinadas a lo largo de las distintas etapas del procesamiento. Las variables del *dataset* se organizaron en las siguientes categorías funcionales:

Identificación y metadatos de la imagen

- **image_id**: Identificador único de la imagen dentro del *dataset*.
- **nombre_imagen**: Nombre original del archivo de imagen.
- **numero_imagen**: Índice numérico asociado a la imagen.
- **carpeta_origen**: Directorio de procedencia de la imagen.
- **imagen**: Referencia o ruta al archivo de imagen.

Etiquetas y clasificación

- **class_name**: Clase inferida a partir de la estructura del *dataset*.
- **clase_real**: Etiqueta real asociada a la imagen.
- **clase_real_patologo**: Etiqueta validada o ajustada por el experto clínico.
- **clase_predicha_raw**: Predicción inicial del modelo de clasificación.
- **clase_predicha**: Predicción final tras posibles ajustes o normalización.
- **probabilidad**: Confianza asociada a la predicción del modelo ViT.

Componente textual generado (BLIP)

- **image_caption_blip_raw**: *caption* generado directamente por BLIP sin procesamiento.
- **image_caption_blip**: *caption* tras aplicar limpieza y normalización básica.
- **caption_blip_util**: Indicador binario que señala si el *caption* contiene información relevante.
- **blip_cues_json**: Representación estructurada de pistas visuales extraídas del *caption*.

Conocimiento experto y representación morfológica

- **class_prototype_morphology_json**: Patrón morfológico esperado por clase.
- **class_prototype_caption**: Descripción textual basada en conocimiento experto.
- **morphology_v2_json**: Representación estructurada refinada de atributos morfológicos.

Fusión multimodal y descripciones finales

- **caption_v2_vlm**: Descripción generada mediante integración multimodal de información visual y conocimiento experto.
- **hybrid_weak_caption**: Descripción resultante de la fusión multimodal de predicción visual y atributos morfológicos.

Configuración experimental y generación

- **model_name**: Modelo utilizado para la generación (BLIP, Gemini-3-flash-preview, etc.).
- **run_id**: Identificador del experimento o ejecución.
- **seed**: Semilla utilizada para reproducibilidad.
- **prompt_version**: Versión del *prompt* utilizado en la generación.
- **temperature/generation_params**: Parámetros de generación del modelo.

Gestión de ejecución y trazabilidad

- **cache_hit**: Indica si la salida fue recuperada desde caché
- **checkpoint_used**: Indica si se utiliza un *checkpoint* previo.
- **retries**: Número de reintentos en la generación.
- **status**: Estado del procesamiento (*ok*, *error*, etc).

Validación estructural y control de calidad

- **qa_valid**: Indicador de validez estructural del registro.
- **qa_errors**: Lista de errores detectados en la validación.
- **missing_fields**: Campos obligatorios ausentes.
- **invalid_values**: Valores fuera del vocabulario permitido.

Finalmente, esta estructura no solo permitió almacenar datos multimodales, sino también representar de forma explícita las distintas etapas del *pipeline*, incluyendo procesos de generación, validación y control de calidad. Esto facilitó la trazabilidad de cada instancia y permitió analizar de forma sistemática el impacto de las estrategias de generación y refinamiento sobre la coherencia descriptiva y semántica de las descripciones generadas.

3.1.2 Componente visual

El componente visual del *dataset* estuvo constituido por imágenes microscópicas de células sanguíneas periféricas organizadas en 12 clases celulares, incluyendo tipos celulares principales y subtipos asociados a diferentes etapas de maduración.

Entre las categorías consideradas se incluyeron clases como *basophil*, *eosinophil*, *erythroblast*, *lymphocyte*, *monocyte* y *platelet*, así como subtipos más específicos como *band*, *myelocyte*, *metamyelocyte*, *promyelocyte*, *segmented* e *ig*. Esta granularidad permitió capturar variaciones morfológicas relevantes, especialmente durante la diferenciación granulocítica.

Las imágenes incorporaron atributos morfológicos clave para el análisis hematológico, incluyendo forma y segmentación nuclear, relación núcleo-citoplasma, distribución de cromatina y presencia de gránulos citoplasmáticos. Estos elementos constituyeron la base de la clasificación celular y de la generación de descripciones morfológicas interpretables.

Las imágenes fueron tratadas de forma homogénea en tamaño, resolución y formato, garantizando una entrada estandarizada para el modelo Vision Transformer (ViT) utilizado en la clasificación celular.

No obstante, el análisis exploratorio evidenció un desbalance entre clases. Algunas categorías, como *eosinophil* o *platelet*, presentaron una representación significativamente mayor que otras, como *promyelocyte* o *ig*. Este desequilibrio introdujo un posible sesgo en el entrenamiento, afectando especialmente a la generalización en clases minoritarias.

Este comportamiento también se reflejó en el componente textual, donde las clases más representadas tendieron a generar descripciones más estables, mientras que las minoritarias mostraron un mayor riesgo de producir *captions* ambiguas o menos precisas desde el punto de vista morfológico.

En conjunto, el componente visual constituyó la base del *dataset* multimodal y condicionó directamente el rendimiento de los modelos de clasificación y generación, justificando la necesidad de los procesos de validación y estructuración desarrollados en este trabajo.

3.1.3 Componente textual

El componente textual del *dataset* estuvo formado por descripciones generadas automáticamente y representaciones estructuradas de atributos morfológicos derivadas de conocimiento experto, evolucionando desde *captions* libres hasta descripciones refinadas y estructuralmente controladas.

En una primera etapa, BLIP generó descripciones en lenguaje natural a partir de las imágenes microscópicas utilizando únicamente información visual. Estas *captions* iniciales (`image_caption_blip_raw`) fueron posteriormente sometidas a procesos de limpieza y normalización (`image_caption_blip`), con el objetivo de reducir expresiones genéricas y contenido poco informativo.

A continuación, se realizó una extracción de pistas visuales estructuradas (`blip_cues_json`), integradas posteriormente con representaciones morfológicas basadas en conocimiento experto (`class_prototype_morphology_json`). Esta combinación permitió construir representaciones enriquecidas que integraron evidencia visual y conocimiento clínico.

En una segunda fase, el *pipeline* incorporó una generación controlada condicionada por vocabularios y atributos morfológicos estructurados. Esta etapa produjo descripciones más consistentes desde el punto de

vista clínico (`caption_v2_vlm`), junto con representaciones estructuradas de atributos relevantes como morfología nuclear, cromatina, citoplasma y granulación (`morphology_v2_json`).

Posteriormente, se desarrollaron dos estrategias de generación textual. La primera correspondió al enfoque canónico (`target_norm_blip_canonico`), basado en la generación de descripciones alineadas con atributos morfológicos estructurados, priorizando precisión morfológica y consistencia terminológica. La segunda correspondió al enfoque híbrido (`target_libre_final`), orientado a generar descripciones más naturales y próximas al lenguaje utilizado en la práctica clínica, manteniendo la coherencia morfológica mediante la integración de atributos estructurados, evidencia visual y conocimiento experto.

Ambos enfoques fueron evaluados mediante auditoría semántica multimodal utilizando Gemini-3-flash-preview, analizando la coherencia imagen-texto e identificando posibles inconsistencias o alucinaciones semánticas.

Finalmente, las descripciones generadas fueron refinadas mediante modelos de lenguaje como Gemma, ajustados con técnicas eficientes basadas en LoRA y Unsloth. De forma complementaria, Qwen3-VL se incorporó como modelo multimodal de referencia para contextualizar el rendimiento del *pipeline*.

En conjunto, el componente textual constituyó un entorno experimental para analizar distintas estrategias de generación, validación y refinamiento, permitiendo estudiar la relación entre estructura morfológica, lenguaje natural y consistencia semántica en modelos visión-lenguaje aplicados a hematología.

3.2 Análisis exploratorio inicial

3.2.1 Distribución de clases

El análisis de la distribución de clases mostró que el *dataset* estuvo compuesto por múltiples categorías celulares, incluyendo tipos celulares principales y subtipos asociados a distintas etapas de maduración. Sin embargo, la distribución no fue uniforme, observándose un desbalance significativo entre clases.

Tal y como se muestra en la **Figura 3**, categorías como *eosinophil*, *platelet* y *segmented* presentaron una representación considerablemente mayor que clases minoritarias como *promyelocyte* o *ig*. Este desequilibrio introdujo un posible sesgo en los modelos de aprendizaje automático, favoreciendo el rendimiento en clases

mayoritarias y dificultando la generalización en aquellas con menor número de instancias.




Figura 3. Distribución de las clases celulares presentes en el dataset utilizado en el estudio. Fuente: Elaboración propia.

En el modelo de clasificación basado en ViT, este comportamiento pudo traducirse en una mayor confianza y precisión para las clases más representadas, así como en un incremento de errores y ambigüedad en categorías minoritarias. Este efecto también se trasladó al componente textual y a las distintas fases de generación multimodal del *pipeline*.

Las clases mayoritarias tendieron a generar descripciones más estructuradas y semánticamente ricas, mientras que las clases minoritarias presentaron una mayor propensión a producir *captions* ambiguas, genéricas o morfológicamente incompletas. Este comportamiento influyó de forma directa en las fases V2 y V3 del pipeline, especialmente en los procesos de generación estructurada, auditoría semántica multimodal y evaluación comparativa entre los enfoques canónico e híbrido.

En conjunto, la distribución de clases constituyó un factor crítico en la consistencia global del *dataset* multimodal, condicionando tanto la alineación imagen-texto como la calidad de las descripciones generadas. Su análisis resultó fundamental para interpretar los resultados experimentales y contextualizar las mejoras introducidas durante las fases de validación y refinamiento.

3.2.2 Variabilidad terminológica

El análisis del componente textual evidenció una notable variabilidad terminológica en las descripciones

generadas automáticamente. Esta variabilidad se manifestó en el uso de sinónimos, diferencias léxicas y expresiones no estandarizadas para describir una misma característica morfológica.

Se identificaron ejemplos como “*round nucleus*” frente a “*regular nucleus*”, variaciones ortográficas como “*cup like*” y “*cup-like*”, así como diferencias en la representación de valores cuantitativos y distintos niveles de detalle descriptivo.

Este fenómeno introdujo ruido semántico en el *dataset*, dificultando la alineación entre imagen-texto y afectando potencialmente al aprendizaje de los modelos visión-lenguaje. Asimismo, la inconsistencia léxica complicó la extracción automática de atributos estructurados, la aplicación de validaciones basadas en reglas morfológicas y la comparación entre estrategias de generación textual.

Para reducir este problema, se implementó un proceso de normalización terminológica basado en vocabularios controlados y conocimiento experto. Esta estrategia permitió unificar expresiones equivalentes, disminuir la ambigüedad semántica y mejorar la consistencia interna del *dataset*, facilitando además la transformación del texto libre en representaciones morfológicas estructuradas.

Estas limitaciones justificaron el desarrollo de las estrategias de generación y refinamiento propuestas en este trabajo, incluyendo el ajuste de modelos BLIP+LoRA, la construcción de representaciones morfológicas estructuradas, el refinamiento textual mediante Gemma y la evaluación multimodal con modelos de referencia como Qwen3-VL.

3.2.3 Análisis de longitud y densidad descriptiva

Se realizó un análisis de la longitud y densidad descriptiva de las *captions* mediante el número de palabras por instancia, con el objetivo de evaluar la variabilidad y calidad del componente textual.

Los resultados mostraron una elevada heterogeneidad, desde descripciones breves y genéricas —como “*a platelet cell*”— hasta descripciones más extensas que incorporaron múltiples atributos morfológicos relevantes.

En general, las descripciones generadas inicialmente por BLIP tendieron a ser cortas y poco específicas, limitando su adecuación morfológico-descriptiva. Por el contrario, las versiones enriquecidas y refinadas presentaron una mayor densidad informativa, incluyendo características como morfología nuclear, patrón de cromatina, relación núcleo-citoplasma y granulación citoplasmática.

No obstante, en algunos casos se observaron descripciones excesivamente largas o redundantes, especialmente en modelos generativos más complejos, lo que pudo introducir repetición innecesaria y afectar a la estabilidad textual.

En consecuencia, se consideró necesario mantener un equilibrio entre longitud y contenido informativo, priorizando descripciones claras, concisas y morfológicamente relevantes.

3.2.4 Problemas estructurales detectados

Durante el análisis exploratorio del *dataset* se identificaron diversos problemas estructurales y semánticos que afectaron a la consistencia del componente textual y al rendimiento potencial de los modelos multimodales:

- **Inconsistencias léxicas:** se observó una elevada variabilidad en la descripción de atributos morfológicos equivalentes, dificultando la consistencia terminológica y la comparación entre descripciones.
- **Ruido en *captions* automáticos:** las descripciones generadas en las fases iniciales del pipeline tendieron a ser genéricas o poco informativas, limitando su adecuación morfológico-descriptiva y semántica.
- **Desbalance de clases:** algunas categorías celulares presentaron una representación significativamente mayor que otras, introduciendo posibles sesgos en el entrenamiento y evaluación de los modelos.
- **Errores de clasificación:** los errores tendieron a concentrarse en células pertenecientes a etapas de maduración cercanas, reflejando la complejidad de distinguir estados morfológicos intermedios.
- **Falta de alineación semántica:** se identificaron casos en los que las descripciones generadas no representaron adecuadamente las características visuales de la imagen, especialmente en atributos morfológicos finos como granulación o morfología nuclear.

En conjunto, estos resultados evidenciaron la necesidad de desarrollar un pipeline de normalización, estructuración y validación capaz de mejorar la consistencia, precisión y calidad descriptiva del *dataset* multimodal.

3.3 Definición del esquema estructurado de atributos

morfológicos

3.3.1 Selección de atributos morfológicos relevantes

Se definió un conjunto de atributos morfológicos relevantes para la interpretación hematológica a partir de conocimiento experto proporcionado por el patólogo, con el objetivo de estructurar las descripciones celulares de forma consistente e interpretable.

Entre los atributos seleccionados se incluyeron el tamaño celular, la relación núcleo/citoplasma, la forma y segmentación nuclear, la cromatina, los nucléolos, las características citoplasmáticas, la coloración, la granulación, las inclusiones y los villi.

La selección respondió tanto a criterios clínicos como a su relevancia en la caracterización morfológica de las distintas líneas celulares. Estos atributos permitieron representar de forma estructurada características nucleares y citoplasmáticas fundamentales para el análisis hematológico.

Asimismo, esta representación facilitó la descomposición de las descripciones en componentes observables, permitiendo evaluar de manera independiente distintas dimensiones morfológicas y analizar qué atributos capturaban correctamente los modelos.

En conjunto, la estructuración basada en atributos morfológicos constituyó un paso clave para transformar texto libre en representaciones interpretables, susceptibles de validación mediante reglas morfológicas y útiles para modelos de aprendizaje automático.

3.3.2 Definición de valores permitidos

Para cada atributo morfológico se definió un conjunto limitado de valores permitidos. Esta discretización permitió reducir la variabilidad léxica, evitar ambigüedades y mantener una representación homogénea entre distintos tipos celulares.

Algunos ejemplos de valores definidos incluyen *small*, *medium* y *large* para tamaño celular; *low*, *medium* y *high* para la relación núcleo/citoplasma; *regular*, *segmented*, *indented* e *irregular* para la forma nuclear; *fine*, *coarse* y *condensed* para la cromatina; *visible* y *not visible* para nucléolos; *scarce*, *moderate* y *abundant* para

el citoplasma; *basophilic*, *eosinophilic* y *grayish* para la coloración citoplasmática; *absent*, *occasional*, *round* *basophilic* y *fine* para la granulación; y *present* o *absent* para inclusiones y *villi*.

La definición de un vocabulario cerrado permitió transformar descripciones libres en representaciones estructuradas y comparables. En el *dataset* original se observó una elevada variabilidad léxica, especialmente en atributos como cromatina o granulación, dificultando el análisis automático.

La normalización terminológica contribuyó a mejorar la alineación semántica del *dataset* y facilitó la evaluación independiente de cada atributo morfológico. Asimismo, permitió reducir la ambigüedad en características complejas y mejorar la estabilidad de las representaciones generadas.

Cuando un atributo no pudo determinarse o no estaba disponible en la fuente original, se utilizó el valor *undefined*, preservando la integridad estructural sin incorporar información incorrecta.

En conjunto, este proceso de discretización constituyó un paso fundamental para facilitar el análisis automático y la integración de las descripciones en modelos de aprendizaje automático.

3.3.3 Representación del esquema

El esquema morfológico se representó en distintos niveles para facilitar tanto su interpretación hematológica como su uso computacional.

3.3.3.1 Modelo conceptual

El modelo conceptual desarrollado se basó en la idea de que cada célula podía describirse mediante un conjunto fijo de atributos morfológicos relevantes para la interpretación hematológica. Cada atributo representó una dimensión específica de la morfología celular y pudo tomar uno de varios valores previamente normalizados.

De este modo, una célula dejó de estar representada únicamente por una etiqueta de clase —por ejemplo, “*neutrófilo segmentado*”— y pasó a describirse mediante una estructura multidimensional más rica, interpretable y relevante desde el punto de vista morfológico.

Este enfoque permitió:

- descomponer las descripciones en componentes observables,
- evaluar el comportamiento de los modelos a nivel de atributo morfológico,

- identificar errores específicos en dimensiones concretas, como cromatina o granulación.

En el contexto de este trabajo, esta representación resultó especialmente útil para analizar de forma estructurada la calidad de las descripciones generadas, independientemente de su formulación textual.

Por ejemplo, un neutrófilo segmentado podía representarse mediante atributos como tamaño celular, forma nuclear, segmentación, cromatina, citoplasma, coloración y granulación. Esta representación estructurada permitió transformar descripciones narrativas en un formato más próximo a una ficha morfológica estructurada, facilitando su validación basada en criterios morfológicos e integración en modelos de aprendizaje automático. Asimismo, el modelo conceptual distinguió entre el nivel semántico, asociado a atributos morfológicos estructurados, y el nivel superficial, correspondiente al texto generado, una separación clave para mitigar problemas como variabilidad léxica, incoherencias semánticas y descripciones genéricas. En conjunto, este modelo constituyó la base del pipeline de extracción, normalización y evaluación de atributos desarrollado en este trabajo.

3.3.3.2 Representación tabular

La representación tabular organiza cada atributo morfológico como una columna y cada célula como una fila. En este trabajo, se utilizó como una estructura derivada de las descripciones textuales y de la auditoría por atributos, ya que los *datasets* base almacenan principalmente texto libre y no atributos explícitos en columnas independientes.

En los archivos de auditoría, los atributos se evaluaron de forma binaria mediante campos del tipo `att_*`, con valores como correcto o incorrecto. Para su presentación en la memoria, se expresan mediante nombres normalizados según la terminología morfológica empleada, como `cell_type`, `cell_size`, `nucleus_shape`, `nuclear_chromatin`, `cytoplasm_color` y `granulation`

Este formato facilita el filtrado, la comparación entre clases celulares y la evaluación estructurada de las descripciones generadas, permitiendo representar y analizar atributos morfológicos de forma interpretable.

Tabla 3. Ejemplo de representación tabular de atributos morfológicos para distintas clases celulares. Fuente: Elaboración propia.

Cell type	Cell size	Nucleus shape	Nuclear chromatin	Cytoplasm color	granulation
neutrophil	medium	segmented	coarse	pale pink	fine
lymphocyte	small	regular	condensed	basophilic	absent
monocyte	high	indented	fine	grayish	occasional

3.3.3.3 Representación en formato JSON

Además de la representación tabular, cada célula puede representarse mediante un objeto JSON. Este formato permite almacenar de forma estructurada los atributos morfológicos asociados a una célula y facilita su uso en procesos automáticos de normalización, generación y evaluación.

Ejemplo:

```
{
  "cell_type": "neutrophil",
  "size": "medium",
  "nucleus_shape": "segmented",
  "nucleus_segments": "3-5",
  "nuclear_chromatin": "coarse",
  "nucleoli": "not visible",
  "cytoplasm_amount": "moderate",
  "cytoplasm_color": "pale pink",
  "granulation": "fine",
  "inclusions": "absent",
  "villi": "absent"
}
```

En el *pipeline* desarrollado, este tipo de representación se utilizó para construir prototipos morfológicos, normalizar descripciones y generar *captions* morfológicamente estructuradas. Además, las auditorías automáticas devolvieron evaluaciones por atributo en formato JSON, con campos como `att_clase celular`, `att_tamano celular`, `att_forma nuclear`, `att_cromatina`, `att_citoplasma` y `att_granulacion`.

Por otra parte, para el *fine-tuning* de Qwen3-VL se utilizó un formato JSONL conversacional, propio de Fireworks, donde cada muestra contiene una imagen codificada en base64, una instrucción textual y la

respuesta esperada. Un ejemplo simplificado sería:

```
{
  "messages": [
    {
      "role": "user",
      "content": [
        {
          "type": "image_url",
          "image_url": {
            "url": "data:image/jpeg;base64,..."
          }
        },
        {
          "type": "text",
          "text": "Cell type: neutrophil. Rewrite the following caption into one clinical sentence..."
        }
      ]
    },
    {
      "role": "assistant",
      "content": "A medium-sized segmented neutrophil shows coarse chromatin, moderate pale cytoplasm and fine granulation."
    }
  ]
}
```

Por tanto, el JSON se empleó en dos niveles complementarios: como representación estructurada de atributos morfológicos y como formato técnico de entrenamiento para modelos multimodales como Qwen3-VL.

3.4 Diseño e implementación del *pipeline* de validación

3.4.1 Normalización terminológica

La normalización terminológica se implementó mediante un vocabulario controlado derivado de conocimiento experto hematológico. Su objetivo principal fue reducir la variabilidad léxica, corregir inconsistencias y mejorar la homogeneidad de las descripciones generadas automáticamente por los distintos modelos.

Para ello, se utilizó un archivo de configuración en formato YAML que incluía reglas de transformación definidas mediante diccionarios de normalización, como `value_map` y `cell_type_map`. Estas reglas permitieron unificar términos equivalentes, corregir errores frecuentes y representar ciertos conceptos de

manera consistente a lo largo de todo el *dataset*.

La normalización se aplicó a atributos morfológicos, nombres celulares, expresiones numéricas y terminología descriptiva, corrigiendo variantes léxicas y unificando formatos. Algunos ejemplos fueron *round* → *regular*, *wde* → *wide*, *3 to 5* → *3-5*, *greyish* → *grayish* y *segmented nucleus* → *segmented*.

Además, este proceso permitió homogeneizar variantes que hacían referencia a una misma entidad celular o rasgo morfológico, evitando que diferencias léxicas superficiales introdujeran ruido en el entrenamiento y en la evaluación posterior de los modelos.

Esta etapa no solo se aplicó a las descripciones generadas por BLIP+LoRA, sino también a las salidas de modelos multimodales como Qwen3-VL y Gemma 3 4B. En el caso de Qwen3-VL, la normalización permitió alinear las descripciones generadas durante el *fine-tuning* con el vocabulario controlado utilizado en el *dataset*, mejorando la coherencia entre entrenamiento y evaluación. Por su parte, en Gemma 3, que genera descripciones en lenguaje natural sin una estructura morfológica explícita, la normalización resultó clave para poder transformar las descripciones en representaciones comparables a nivel de atributos morfológicos.

Asimismo, la normalización facilitó la posterior fase de auditoría automática basada en atributos, ya que permitió mapear las descripciones generadas por los distintos modelos a un espacio semántico común. Esto fue especialmente relevante en la evaluación comparativa, donde se requería medir el rendimiento de modelos heterogéneos bajo criterios clínicos homogéneos.

En conjunto, esta etapa permitió obtener *captions* más homogéneas, comparables y morfológicamente coherentes, constituyendo un paso fundamental para el *fine-tuning*, la evaluación automática y la interpretación de los resultados.

3.4.2 Extracción automática de atributos

Las descripciones generadas combinan dos fuentes de información complementarias: información visual, obtenida mediante modelos visión-lenguaje como BLIP+LoRA, Qwen3-VL o Gemma 3, y conocimiento experto, derivado del *dataset* y del conocimiento hematológico incorporado durante el proceso de normalización y refinamiento.

A partir de estas fuentes, se construye una descripción final que integra ambas perspectivas, permitiendo capturar tanto la apariencia visual como las características morfológicas de la célula.

Posteriormente, estas descripciones son transformadas en representaciones estructuradas mediante la extracción automática de atributos (tamaño, forma nuclear, cromatina, citoplasma, granulación, etc.), lo que permite su validación cuantitativa.

Este proceso corresponde al enfoque híbrido de generación, al combinar la capacidad de los modelos para capturar información visual con la precisión y robustez del conocimiento experto. Asimismo, la estructuración en atributos facilita la comparación entre modelos heterogéneos y permite evaluar sus resultados bajo criterios clínicos homogéneos.

3.4.3 Validación basada en reglas

Además de la normalización terminológica, se implementó un sistema de validación basado en reglas para garantizar la coherencia interna de las descripciones generadas. Estas reglas permitieron detectar inconsistencias entre atributos morfológicos, valores imposibles o combinaciones poco plausibles desde el punto de vista hematológico, verificar la presencia de todos los atributos definidos en el esquema estructurado (asignando el valor *undefined* cuando no podían determinarse) y eliminar repeticiones innecesarias, corregir problemas de formato y asegurar el uso de términos compatibles con el vocabulario controlado. Este proceso contribuyó a mejorar la calidad final del *dataset* y reducir errores semánticos antes del entrenamiento de los modelos.

3.4.4 Métricas estructurales y semánticas

Para evaluar la calidad del *dataset* y de las descripciones generadas, se utilizaron diversas métricas aplicadas de forma homogénea a todos los modelos considerados (BLIP+LoRA, Gemma 3 y Qwen3-VL).

En el componente visual, se emplearon métricas estándar de clasificación como la precisión (accuracy) y el F1-score, tanto en su versión ponderada (weighted) como macro, con el objetivo de evaluar el rendimiento global del modelo y su comportamiento ante el desbalance entre clases. Asimismo, se analizó la matriz de confusión para identificar patrones de error entre clases morfológicamente similares.

En el componente textual, se utilizaron métricas de similitud como BLEU, METEOR y BERTScore para evaluar la calidad de las descripciones generadas por los distintos modelos. Estas métricas permitieron capturar tanto la coincidencia léxica como la similitud semántica entre las descripciones generadas y las descripciones morfológicas de referencia.

Dado que modelos como Gemma 3 y Qwen3-VL generan descripciones en lenguaje natural sin estructura morfológica explícita, se incorporó un proceso adicional de normalización y extracción de atributos que permite transformar dichas descripciones en representaciones comparables con las generadas por BLIP+LoRA.

Además, se definió una evaluación estructural basada en atributos morfológicos, que permitió analizar la calidad de las descripciones a nivel morfológico. Este enfoque evalúa de forma independiente dimensiones como el tamaño celular, la forma nuclear, la cromatina o la granulación, proporcionando una medida más interpretable que las métricas textuales tradicionales.

Finalmente, se realizó una auditoría automática mediante un modelo multimodal externo (Gemini-3-flash-preview), que evalúa la coherencia entre imagen y descripción, clasificando los resultados en categorías como correcto, error leve de atributos o incoherencia semántica, e incorporando indicadores de adecuación morfológico-descriptiva. Las definiciones formales, criterios de cálculo y formulaciones matemáticas de las métricas empleadas en este trabajo se recogen en el **Anexo 2**, con el objetivo de facilitar la reproducibilidad y la correcta interpretación de los resultados.

3.4.5 Evaluación semántica mediante varios modelos LLM

Con el objetivo de evaluar la calidad semántica de las descripciones generadas, se realizó una comparación entre distintos modelos de lenguaje y visión-lenguaje. En concreto, se analizaron las captions producidas por BLIP base, las distintas versiones fine-tuned de BLIP (v1, v2, v3 y variantes con LoRA), BLIP+LoRA (enfoques canónico e híbrido), Gemma 3 4B VLM condicionado y Qwen3-VL fine-tuned.

Para cada muestra, la descripción generada se comparó con la descripción objetivo normalizada (**target_norm**), analizando la longitud descriptiva, el solapamiento léxico, la presencia de repeticiones, el grado de especificidad y la consistencia global de la descripción. Dado que varios modelos generaban lenguaje natural (texto libre), se aplicaron procesos adicionales de normalización y extracción automática de atributos para transformar las salidas en representaciones estructuradas comparables.

Además, se utilizó Gemini-3-flash-preview como auditor multimodal automático para analizar y clasificar de forma sistemática los errores presentes en las descripciones generadas. Como mecanismo adicional de validación, Qwen2.5-VL actuó como segundo auditor independiente sobre una muestra estratificada, permitiendo estimar la concordancia entre evaluadores y analizar la robustez del proceso de auditoría.

La evaluación consideró errores morfológicos en atributos como tamaño celular, cromatina o granulación, así

como omisiones de información relevante, uso inconsistente de terminología, repeticiones, descripciones genéricas, incoherencias imagen-texto y errores de clasificación celular.

Este análisis permitió comparar los modelos más allá de las métricas textuales tradicionales, identificando diferencias en precisión morfológica, coherencia semántica y calidad descriptiva. Los resultados mostraron que BLIP+LoRA híbrido ofreció la representación morfológica más consistente, mientras que Gemma 3 4B VLM condicionado destacó por la fluidez textual y Qwen3-VL fine-tuned por sus capacidades multimodales, aunque con una mayor variabilidad estructural.

3.5 Arquitectura de reproducibilidad

Con el objetivo de garantizar la reproducibilidad del trabajo, se definió una arquitectura estructurada que abarca tanto la organización del repositorio como el diseño del *pipeline* experimental completo.

Todos los componentes necesarios para reproducir los experimentos se encuentran organizados en carpetas específicas, incluyendo el código fuente del pipeline, los modelos entrenados (BLIP+LoRA y sus variantes canónica e híbrida), los *datasets* utilizados en sus distintas fases (original, filtrado, enriquecido y final), las predicciones generadas por BLIP, Gemma 3 y Qwen3-VL, los resultados de evaluación y auditoría, los archivos de configuración asociados a la normalización terminológica, vocabularios controlados y *prompts*, así como la documentación técnica y los recursos bibliográficos del proyecto.

Con el fin de facilitar la portabilidad, las rutas utilizadas en los notebooks se definieron de forma relativa a la raíz del proyecto, permitiendo ejecutar el *pipeline* completo sin necesidad de modificar manualmente las ubicaciones de los archivos.

El *pipeline* se diseñó de forma modular, de manera que cada etapa genera salidas intermedias persistentes. Esto permite no solo reproducir los resultados finales, sino también inspeccionar y reutilizar cada fase del proceso de forma independiente. En particular, se almacenan de forma explícita:

- Predicciones del modelo de clasificación visual (ViT).
- *Captions* generadas por BLIP en sus distintas versiones.
- Descripciones refinadas mediante BLIP+LoRA y postprocesado híbrido.
- Salidas generadas por modelos externos (Gemma 3 y Qwen3-VL).
- Representaciones estructuradas en atributos morfológicos.
- Resultados de auditoría automática (Gemini-3-flash-preview).

- Errores de clasificación, errores semánticos y fallos por atributo.
- Métricas cuantitativas y matrices de confusión.

Además, se incorporaron mecanismos de guardado automático y generación de copias de seguridad durante las etapas críticas del *pipeline* (procesamiento de imágenes, generación de *captions* y construcción del *dataset*), lo que permite recuperar el progreso en caso de interrupciones.

Para asegurar la trazabilidad experimental, cada archivo incorpora identificadores de versión y referencias a la configuración utilizada. Los notebooks, modelos y *datasets* derivados se almacenaron en plataformas como Hugging Face y Google Drive, favoreciendo la transparencia y difusión de los resultados.

3.6 Resumen metodológico




Figura 4. Pipeline multimodal propuesto para el análisis morfológico en hematología digital. El flujo integra clasificación visual, generación de captions, normalización terminológica, extracción de atributos, fine-tuning, refinamiento textual y auditoría multimodal. Fuente: Elaboración propia.

La metodología propuesta en este trabajo combina técnicas de visión por computador, modelos visión-lenguaje (VLM) y procesamiento de lenguaje natural, integradas con conocimiento experto en hematología.

En una primera fase, se construyó un *dataset* multimodal a partir de imágenes de células sanguíneas y descripciones generadas automáticamente mediante modelos como BLIP. Este *dataset* inicial presenta características propias de entornos reales, incluyendo variabilidad léxica, ruido semántico y desbalance de clases.

A continuación, se realizó un análisis exploratorio para identificar problemas estructurales y semánticos en las descripciones, tales como inconsistencias terminológicas, *captions* genéricos o falta de alineación imagen-texto.

Sobre esta base, se diseñó un pipeline que integra normalización terminológica mediante vocabularios controlados, definición de atributos morfológicos relevantes para la interpretación hematológica, transformación de descripciones en lenguaje natural en representaciones estructuradas e incorporación de conocimiento experto en la generación de descripciones.

La **Figura 4** resume la arquitectura general del pipeline multimodal desarrollado. El flujo integra la clasificación visual mediante ViT, la generación inicial de descripciones con BLIP, la normalización terminológica, la extracción de atributos morfológicos, el ajuste mediante BLIP+LoRA, el refinamiento con modelos de lenguaje y la auditoría automática con modelos multimodales. Esta representación permite visualizar la trazabilidad entre imagen, descripción, atributos estructurados y métricas de evaluación.

En el núcleo del enfoque propuesto, se desarrollaron dos estrategias de *fine-tuning* con BLIP+LoRA. La primera correspondió al enfoque canónico, orientado a generar descripciones estructuradas basadas en atributos morfológicos para maximizar la estabilidad y facilitar la evaluación automática. La segunda correspondió al enfoque híbrido, orientado a generar descripciones en lenguaje natural más próximas al estilo clínico, combinando atributos estructurados, conocimiento experto y procesos de normalización para mantener la coherencia morfológica y la consistencia descriptiva.

Además, se incorporaron modelos complementarios para el refinamiento, comparación y evaluación de las descripciones generadas. En particular, Gemma 3 4B se empleó para el refinamiento textual, Qwen3-VL como modelo multimodal de referencia y Gemini-3-flash-preview para la auditoría automática y evaluación morfológica.

Este enfoque permite unificar las salidas de modelos heterogéneos en un mismo espacio semántico basado en

atributos, facilitando su comparación y validación bajo criterios clínicos homogéneos.

Como resultado, se obtiene un *dataset* refinado, consistente y clínicamente interpretable, adecuado para el *fine-tuning* de modelos visión-lenguaje basados en atributos morfológicos.

Capítulo 4

4. Resultados

4.1 Resultados del proceso de validación estructural

4.1.1 Metodología de validación

La validación estructural del *dataset* se desarrolló mediante un pipeline basado en un modelo de clasificación Vision Transformer (ViT) y un modelo de generación automática de descripciones BLIP base. El objetivo principal de esta fase fue construir un *dataset* multimodal estructurado y evaluar la alineación entre las clases reales, las predicciones visuales y las descripciones generadas automáticamente.

Inicialmente, se partió de un conjunto de 16.503 imágenes de células sanguíneas periféricas. Esta versión correspondió a una fase adicional de limpieza y control de calidad respecto a versiones previas utilizadas durante el desarrollo del proyecto, donde se emplearon 17.092 imágenes. La reducción del conjunto de datos respondió a la eliminación de muestras ambiguas o inconsistentes, priorizando la calidad y consistencia del *dataset* sobre su tamaño total.

Durante el desarrollo se detectaron inconsistencias en las categorías de immature granulocytes (IG), especialmente entre las subclases *promyelocyte*, *myelocyte* y *metamyelocyte*. Para evitar ambigüedades y asegurar la coherencia de las etiquetas celulares, se reconstruyó la taxonomía utilizando 12 subclases definidas a partir del nombre de archivo de cada imagen. Esta decisión redujo ligeramente las métricas de clasificación, pero permitió trabajar con categorías más robustas desde el punto de vista clínico y metodológico.

Posteriormente, se implementó un *dataset* personalizado en PyTorch y las imágenes se procesaron mediante ViTImageProcessor, utilizando el modelo preentrenado google/vit-base-patch16-224. El conjunto de datos se dividió de forma estratificada en entrenamiento (80 %), validación (10 %) y test (10 %), preservando la distribución de las subclases celulares en cada partición.

El modelo ViTForImageClassification se ajustó al número final de clases y se entrenó durante cinco *epochs*, utilizando una *learning rate* de $2e-5$ y un *batch size* de 32 imágenes. La selección del mejor *checkpoint* se realizó utilizando la métrica F1 ponderada (f1_weighted), al considerarse más adecuada para un escenario con

clases desbalanceadas. Durante la evaluación se calcularon métricas de *accuracy*, *precision*, *recall* y *F1-score*.

Una vez entrenado el modelo, se utilizó en inferencia para predecir la clase celular de cada imagen y la probabilidad asociada a dicha predicción. Paralelamente, las imágenes se procesaron con BLIP base (Salesforce/blip-image-captioning-base) para generar *captions* automáticas. La generación se realizó mediante *beam search* (num_beams = 4) y un máximo de 40 tokens, aplicando penalización de repetición (*repetition_penalty* = 1.15) para reducir redundancias.

Las *captions* generadas fueron sometidas a un proceso de limpieza y normalización. Se eliminaron expresiones genéricas frecuentes, como “*a blood cell*” o “*microscopic image of*”, además de repeticiones, fragmentos vacíos y descripciones derivadas directamente del *prompt*. Posteriormente, se aplicó un sistema heurístico basado en reglas para distinguir descripciones útiles de salidas no informativas.

Este filtrado se basó en la detección de atributos morfológicos específicos, incluyendo forma nuclear, cromatina, granulación y características citoplasmáticas. Solo se consideraron útiles las descripciones con información relevante desde el punto de vista hematológico. El análisis mostró que BLIP base generó descripciones morfológicamente adecuadas en una proporción reducida del *dataset* (65 imágenes), predominando salidas excesivamente genéricas o poco alineadas con la morfología celular observada.

Para mejorar la fiabilidad del sistema, se incorporó conocimiento experto mediante prototipos morfológicos definidos para cada subclase celular. Estos se construyeron a partir de atributos estructurados proporcionados por el patólogo y se combinaron con los rasgos visuales detectados por BLIP mediante reglas heurísticas que priorizaban atributos relevantes como la segmentación nuclear, la granulación y la cromatina.

Finalmente, toda la información generada se almacenó en un *dataset* estructurado que integró imágenes, clases reales, predicciones, probabilidades, *captions* originales, atributos morfológicos estructurados y descripciones refinadas. Además, se diferenciaron explícitamente errores técnicos de procesamiento y errores de clasificación, lo que permitió analizar de forma independiente la calidad del *pipeline* y el comportamiento del modelo.

4.1.2 Resultados cuantitativos

La validación estructural se realizó sobre un total de 16.503 imágenes correspondientes a 12 subclases celulares hematológicas, **Tabla 4**. El modelo ViT alcanzó una *accuracy* global del 98,14 %, junto con un F1 ponderado de

0,9814 y un F1 macro de 0,9775, reflejando un rendimiento elevado y equilibrado entre las distintas categorías celulares analizadas.

La diferencia reducida entre las métricas macro y ponderadas sugiere que el modelo mantuvo un comportamiento relativamente homogéneo incluso en las subclases minoritarias, a pesar del desbalance de los datos. En conjunto, estos resultados indican que la reformulación del pipeline basada en subclases finas permitió construir un clasificador visual más consistente y sólido metodológicamente.

Las principales confusiones se concentraron entre subclases morfológicamente próximas, especialmente entre *promyelocyte*, *myelocyte* y *metamyelocyte*, así como entre *band* y *segmented*. Estas confusiones resultan esperables desde el punto de vista hematológico, ya que corresponden a estadios consecutivos de maduración celular con diferencias morfológicas sutiles. En contraste, las clases más diferenciadas, como *eosinophil*, *platelet* o *ig*, mostraron una separación casi completa dentro de la matriz de confusión.

En paralelo, el análisis de las *captions* generadas mediante BLIP base evidenció limitaciones semánticas importantes. Aunque el modelo generó descripciones visualmente correctas, la mayoría de *captions* carecieron de información morfológica suficientemente específica para su interpretación hematológica. Únicamente 65 imágenes (0,39 % del *dataset*) produjeron *captions* consideradas útiles tras el filtrado heurístico basado en atributos hematológicos.

Estos resultados justificaron la incorporación posterior de prototipos morfológicos y reglas de integración basadas en conocimiento experto para reforzar la consistencia descriptiva y mejorar la calidad semántica de las descripciones generadas por el sistema.

Tabla 4. Métricas cuantitativas empleadas para evaluar la calidad estructural y semántica del dataset. Fuente: Elaboración propia.

Métrica	Valor
Registros analizados	16.503
Registros correctamente clasificados	16.196
Errores de clasificación	1,86 %
<i>Exactitud (Accuracy) del modelo ViT</i>	98,14 %
<i>Captions útiles generadas por BLIP</i>	0,39 % (65 imágenes)




Figura 5. Matriz de confusión normalizada por filas del clasificador ViT sobre las 12 clases celulares. Cada fila representa la distribución porcentual de predicciones para una clase real. Fuente: Elaboración propia.

4.1.3 Análisis de resultados

Los resultados obtenidos mostraron un alto grado de consistencia estructural en el *dataset*, con una accuracy global del 98,14 % en la clasificación automática de células sanguíneas. La matriz de confusión reflejó un rendimiento sólido en la mayoría de subclases celulares, concentrándose los errores principalmente entre células con estadios de maduración próximos, como *band* y *segmented*, o *promyelocyte*, *myelocyte* y *metamyelocyte*.

Estas confusiones resultaron esperables desde el punto de vista hematológico, ya que correspondían a subclases con diferencias morfológicas sutiles relacionadas con la segmentación nuclear y condensación de la cromatina. En conjunto, los resultados indicaron que el modelo ViT proporcionó una base visual sólida para la construcción del *dataset* multimodal.

En contraste, el componente textual presentó limitaciones relevantes. Aunque BLIP base fue capaz de generar descripciones para todas las imágenes, únicamente 65 *captions* (0,39 % del *dataset*) fueron consideradas útiles desde el punto de vista clínico. La mayoría de las descripciones resultaron excesivamente genéricas y carecieron de atributos hematológicos relevantes, como cromatina, granulación o relación núcleo/citoplasma.

Estos resultados evidenciaron una diferencia clara entre la elevada fiabilidad alcanzada por el componente visual y la limitada capacidad inicial de los modelos generalistas de *captioning* para representar adecuadamente la morfología hematológica. Esta limitación justificó la incorporación posterior de estrategias de refinamiento, conocimiento experto y validación semántica en el pipeline.

4.1.4 Implicaciones para el *dataset*

La validación estructural confirmó que el componente visual del *dataset* era suficientemente robusto para servir como base del pipeline multimodal. Sin embargo, el análisis del componente textual mostró que las *captions* generadas directamente mediante BLIP base no resultaban adecuadas para describir de forma precisa la complejidad morfológica de las células sanguíneas.

Esta asimetría entre imagen-texto puso de manifiesto la necesidad de incorporar mecanismos adicionales de refinamiento y conocimiento experto. Para ello, se integraron atributos morfológicos estructurados, incluyendo tamaño celular, relación núcleo/citoplasma, forma nuclear, cromatina, granulación y características citoplasmáticas.

A partir de esta validación inicial, se desarrollaron distintas estrategias orientadas a reducir la brecha semántica entre imagen-texto. En particular, se evaluaron configuraciones basadas en BLIP+LoRA canónico, centrado en la representación explícita de atributos morfológicos, así como configuraciones BLIP+LoRA libre base, BLIP+LoRA libre mejorado y BLIP+LoRA híbrido, orientadas a generar descripciones más naturales y clínicamente interpretables manteniendo la coherencia estructural.

Entre las configuraciones evaluadas, BLIP+LoRA híbrido se priorizó como configuración final al ofrecer el mejor equilibrio entre interpretabilidad, consistencia descriptiva y fidelidad morfológica. En conjunto, estos resultados mostraron que la utilidad del *dataset* multimodal no dependía únicamente de la calidad visual de las imágenes, sino también de la capacidad del pipeline para generar descripciones coherentes mediante procesos de refinamiento, validación y control semántico.

4.2 Evaluación semántica mediante modelos de lenguaje

4.2.1 Metodología de evaluación automática con Gemini-3-flash-preview

La evaluación semántica de las descripciones generadas incorporó Gemini-3-flash-preview como herramienta automática de apoyo a la auditoría multimodal, permitiendo analizar coherencia textual, precisión morfológica y adecuación morfológico-descriptiva de forma homogénea entre los distintos modelos evaluados.

En una primera fase, la evaluación se centró en analizar las limitaciones iniciales de BLIP base y evaluar la mejora obtenida tras las distintas etapas de ajuste fino. Para ello, se compararon las salidas de BLIP base, BLIP *fine-tuned* v1 y BLIP *fine-tuned* v2.

Posteriormente, el mismo esquema de evaluación se extendió a configuraciones más avanzadas, incluyendo BLIP+LoRA canónico, BLIP+LoRA libre base, BLIP+LoRA libre mejorado, BLIP+LoRA híbrido, Gemma 3 4B VLM condicionado por BLIP+LoRA y Qwen3-VL *fine-tuned*.

Dado que estos modelos generaban descripciones con distintos niveles de estructura, desde plantillas basadas en atributos hasta descripciones en lenguaje natural, el uso de Gemini-3-flash-preview permitió aplicar un criterio de evaluación homogéneo y facilitar la comparación entre enfoques heterogéneos.

4.2.2 Definición de criterios de evaluación

Los criterios de evaluación se definieron a partir de las categorías incluidas en los prompts de Gemini-3-flash-preview. Cada descripción fue clasificada en una categoría de error para valorar su calidad semántica y morfológica: correcto, descripción genérica, error de clasificación, incoherencia semántica, repetición o error leve de atributos.

Además de las etiquetas globales, se registró el atributo fallido cuando existía un error morfológico específico. Entre los atributos evaluados se incluyeron la clase celular, el tamaño, la relación núcleo/citoplasma, la forma y segmentación nuclear, la cromatina, los nucléolos, las características citoplasmáticas, el color, la granulación, las inclusiones y las proyecciones citoplasmáticas (villi).

También se incorporaron criterios adicionales de evaluación, como gravedad del error, adecuación morfológico-descriptiva de la descripción y mejora respecto al input inicial. Esta estructura permitió analizar no solo si una descripción era globalmente correcta, sino también qué atributos morfológicos estaban correctamente representados y cuáles afectaban a su adecuación morfológico-descriptiva.

4.2.3 Protocolo de evaluación

Para cada instancia del *dataset* se construyó un *prompt* estructurado que incluía la clase celular real, la descripción objetivo y las *captions* generadas por los distintos modelos evaluados. Gemini-3-flash-preview actuó como evaluador automático, asignando una etiqueta de calidad a cada descripción en función de su coherencia semántica y precisión morfológica.

El protocolo se aplicó inicialmente sobre las salidas de BLIP base, BLIP fine-tuned v1 y BLIP fine-tuned v2, y posteriormente se extendió a configuraciones más avanzadas del pipeline, incluyendo BLIP+LoRA canónico, BLIP+LoRA libre base, BLIP+LoRA libre mejorado, BLIP+LoRA híbrido, Gemma 3 4B VLM y Qwen3-VL fine-tuned.

La evaluación se diseñó siguiendo una estructura controlada basada en categorías predefinidas de error, permitiendo registrar tanto la clasificación global de la descripción como información adicional sobre atributos morfológicos afectados, gravedad del error, adecuación morfológico-descriptiva y mejora respecto al input inicial.

En las fases más avanzadas del pipeline, la evaluación se realizó tanto en configuración unimodal (solo texto) como multimodal (imagen-texto), permitiendo comparar directamente las descripciones generadas con la morfología observada en la imagen original. El prompt empleado durante este proceso de evaluación automática se presenta íntegramente en el Anexo 3.

4.2.4 Resultados cuantitativos de la evaluación con Gemini-3-flash-preview

La evaluación semántica con Gemini-3-flash-preview se realizó en dos configuraciones: una unimodal, basada solo en información textual y otra multimodal, en la que también se incorporó la imagen original. Esta segunda configuración permitió comprobar si las descripciones generadas eran coherentes no solo con el texto objetivo, sino también con la morfología celular observada.

En la primera fase se compararon BLIP base, BLIP v1 y BLIP v2. BLIP base mostró una limitación clara: el 98,83 % de sus salidas fueron clasificadas como descripciones genéricas, confirmando que el modelo preentrenado era capaz de generar *captions* visuales generales, pero insuficiente para describir rasgos hematológicos específicos. Tras el *fine-tuning* se observó una mejora progresiva: BLIP v1 alcanzó un 44,16 % de descripciones correctas, aunque mantuvo errores de clasificación e incoherencias semánticas, mientras que BLIP v2 elevó este porcentaje hasta el 65,23 % en evaluación textual y redujo las descripciones genéricas al 0,18

%. Sin embargo, cuando Gemini evaluó BLIP v2 con acceso a la imagen original, el porcentaje de descripciones correctas descendió al 56,39 %, evidenciando que algunas *captions* eran coherentes a nivel textual, pero no completamente fieles a la morfología observada. Los errores restantes afectaron principalmente a atributos finos como citoplasma, granulación y segmentación nuclear.

Tabla 5. Distribución porcentual de los tipos de error detectados en las descripciones generadas por BLIP base, BLIP v1 y BLIP v2. Fuente: Elaboración propia.

Tipo de error	BLIP base (%)	BLIP v1 (%)	BLIP v2 (solo texto) (%)	BLIP v2 (imagen - texto) (%)
Correcto	0,00	44,16	65,23	56,39
Descripción genérica	98,83	0,37	0,18	9,34
Error de clasificación	0,74	22,60	7,25	8,66
Error leve de atributos	0,00	12,53	23,77	11,06
Incoherencia semántica	0,25	18,98	2,70	8,48
Repetición	0,18	1,11	0,55	6,08

Estos resultados correspondieron a las primeras fases de adaptación del modelo BLIP al dominio hematológico. Posteriormente, se evaluaron configuraciones más avanzadas basadas en BLIP+LoRA canónico, BLIP+LoRA libre base, BLIP+LoRA libre mejorado y BLIP+LoRA híbrido, cuyos resultados se presentan en las secciones siguientes.

En una segunda fase se evaluaron configuraciones más avanzadas del pipeline. BLIP+LoRA híbrido obtuvo el resultado más equilibrado, alcanzando un 58,85 % de descripciones correctas, calculado como la proporción de casos clasificados como correcto por el auditor multimodal sobre el total de descripciones evaluadas. Asimismo, obtuvo un 83,80 % de correcto ampliado, definido como la proporción de descripciones clasificadas como correcto o error leve de atributos. Por último, alcanzó un 80,95 % de descripciones valoradas con alta adecuación morfológico-descriptiva, correspondiente al porcentaje de casos considerados coherentes y suficientemente informativos desde el punto de vista morfológico. Estos resultados sugieren que la combinación de LoRA, control morfológico y enfoque híbrido mejoró la calidad global de las descripciones generadas.

Gemma 3 4B VLM condicionado obtuvo un correcto ampliado del 94,04 % y una alta adecuación morfológico-descriptiva del 69,28 %, lo que indicó buena fluidez y plausibilidad global. Sin embargo, presentó más errores leves de atributos. Qwen3-VL *fine-tuned* alcanzó el mayor correcto ampliado, con un 99,74 %, pero su menor estabilidad en atributos concretos limitó su utilidad para la validación basada en criterios morfológicos.

Tabla 6. Comparativa global entre modelos tras evaluación con Gemini-3-flash-preview. Fuente: Elaboración propia.

Modelo	% correcto global	% correcto ampliado	% error leve atributos	% utilidad alta	% mejora
BLIPv3 libre base	0,06	-	53,92	50,36	100,0
BLIP+LoRA libre mejorado	0,97	35,71	34,74	31,11	31,17
BLIP+LoRA híbrido	58,85	83,80	24,95	80,95	80,43
Gemma 3 4B VLM condicionado	39,60	94,04	54,44	69,28	76,02
Qwen3-VL fine-tuned	44,65	99,74	55,09	74,72	44,91

En conjunto, los resultados mostraron que el rendimiento no dependió únicamente de utilizar modelos generativos más potentes. **BLIP v3 libre base** constituyó el punto de partida de la línea experimental libre, aunque resultó insuficiente por sí solo. Las mejoras más relevantes aparecieron al combinar técnicas de *fine-tuning*, adaptación mediante LoRA, conocimiento experto, validación semántica y **BLIP+LoRA híbrido**, configuración que permitió mejorar simultáneamente la consistencia descriptiva y fidelidad morfológica de las descripciones generadas.

4.2.5 Análisis cualitativo

Con el objetivo de complementar los resultados cuantitativos, se realizó un análisis cualitativo de las evaluaciones generadas por Gemini-3-flash-preview. Este análisis permitió revisar qué tipo de errores aparecían y qué atributos morfológicos se veían afectados.

BLIP base generó principalmente descripciones genéricas, con escaso contenido morfológico relevante. En muchos casos, las *captions* describían la imagen de forma superficial, sin mencionar rasgos como cromatina, granulación, citoplasma o segmentación nuclear.

Las versiones ajustadas mediante *fine-tuning* mejoraron de forma progresiva. BLIP v1 introdujo una estructura

descriptiva más clara, aunque todavía presentó errores de clasificación e incoherencias. BLIP v2 produjo descripciones más completas y mejor alineadas con la clase celular, aunque siguió fallando en atributos finos.

La evaluación multimodal permitió detectar errores no siempre visibles en una evaluación exclusivamente textual. Por ejemplo, se observaron casos en los que un mielocito fue descrito como metamielocito, o células en banda como neutrófilos segmentados con varios lóbulos. También aparecieron contradicciones morfológicas, como basófilos descritos con granulación eosinofílica, y repeticiones en la descripción de la cromatina, como “homogeneous/open/homogeneous/open/low condensed chromatin”.

Las configuraciones posteriores redujeron parte de estos problemas. Mientras que BLIP v3 libre base mejoró la calidad descriptiva respecto a las versiones iniciales, BLIP+LoRA híbrido fue la configuración que mostró mayor estabilidad descriptiva y morfológica. Gemma 3 4B VLM condicionado produjo textos más fluidos y naturales, aunque en algunos casos introdujo detalles no claramente observables. Qwen3-VL fine-tuned generó descripciones globalmente plausibles, pero con menor estabilidad en atributos concretos.

En conjunto, el análisis cualitativo mostró que la dificultad principal no estaba solo en reconocer la clase celular, sino en describir con precisión sus rasgos morfológicos finos.

4.2.6 Análisis de robustez mediante un segundo auditor multimodal (Qwen2.5-VL)

Con el objetivo de reducir el posible sesgo asociado al uso de Gemini como evaluador único, se incorporó un segundo auditor multimodal independiente basado en Qwen2.5-VL. Este modelo reevaluó una muestra estratificada de 200 imágenes utilizando el mismo protocolo empleado durante la auditoría principal con Gemini, basado en cuatro dimensiones: (1) tipo de error detectado (descripción genérica, error de clasificación, incoherencia semántica, repetición o error leve de atributos), (2) atributo morfológico afectado, (3) gravedad del error y (4) calidad descriptiva. Esta muestra no sustituye a la evaluación completa del conjunto de test, sino que se empleó como análisis adicional de robustez y concordancia entre auditores automáticos.

La concordancia entre ambos evaluadores se cuantificó mediante porcentaje de acuerdo y coeficiente κ de Cohen. Se obtuvo un acuerdo del 59,0% para la clasificación de errores y del 32,0% para la evaluación de gravedad. Los coeficientes κ obtenidos fueron $\kappa = -0,0103$ para clasificación de errores y $\kappa = 0,0994$ para gravedad.

El análisis detallado de las discrepancias mostró diferencias sistemáticas entre ambos modelos. En particular, Qwen2.5-VL tendió a clasificar como correctas numerosas descripciones que Gemini identificó como excesivamente genéricas. De las 58 descripciones consideradas genéricas por Gemini, 57 fueron clasificadas

como correctas por Qwen2.5-VL. Este comportamiento sugiere la existencia de criterios implícitos diferentes respecto al nivel de especificidad morfológica requerido durante la evaluación.

Concordancia y discrepancias entre Gemini-3-flash-preview y Qwen2.5-VL




Figura 6. Diagrama aluvial de concordancia entre Gemini-3-flash-preview y Qwen2.5-VL en una muestra estratificada de 200 imágenes. Fuente: Elaboración propia.

La **Figura 6** muestra un diagrama aluvial de las discrepancias observadas entre ambos modelos, permitiendo visualizar la redistribución de categorías y los principales puntos de desacuerdo.

En conjunto, estos resultados sugieren que la utilización de un único evaluador automático puede introducir sesgos asociados a criterios internos del modelo empleado. En este contexto, Qwen2.5-VL se utilizó como mecanismo adicional de análisis de robustez, mientras que Gemini se mantuvo como auditor principal al aplicar un criterio más conservador orientado a minimizar la aceptación de descripciones insuficientemente específicas.

4.2.7 Limitaciones del modelo evaluador

Aunque Gemini-3-flash-preview permitió realizar una evaluación automática consistente y escalable, su uso presentó algunas limitaciones.

En primer lugar, el modelo tendió a ser estricto al diferenciar entre descripciones completamente correctas y

errores leves de atributos. Esto hizo que algunas descripciones morfológicamente adecuadas fueran penalizadas por pequeñas discrepancias relacionadas con citoplasma, granulación, cromatina o relación núcleo/citoplasma.

También se observó cierta sensibilidad a la forma del texto. Cambios menores en la formulación de un atributo o en el orden de los términos podían afectar a la evaluación, aunque el significado clínico subyacente fuera equivalente. Del mismo modo, algunas expresiones redundantes fueron clasificadas como repeticiones, aun cuando parte de la información morfológica seguía siendo informativamente relevante.

Con el objetivo de reducir parcialmente este sesgo, se incorporó un segundo auditor multimodal independiente basado en Qwen2.5-VL sobre una muestra estratificada de 200 imágenes. Esta validación adicional permitió identificar diferencias en los criterios implícitos de evaluación entre ambos modelos y analizar la robustez del proceso de auditoría automática. No obstante, las discrepancias observadas entre ambos evaluadores pusieron de manifiesto que la valoración automática continúa dependiendo de decisiones internas propias de cada modelo.

Otra limitación importante fue que ninguno de los evaluadores automáticos utilizados sustituyó una validación clínica experta. En células con estadios de maduración próximos, como mielocitos y metamielocitos, podían existir discrepancias interpretativas incluso entre observadores humanos especializados.

Por tanto, la evaluación automática se utilizó como una herramienta útil para comparar modelos a gran escala, pero no como un mecanismo de validación clínica definitiva. Futuros trabajos podrían incorporar revisión directa por especialistas en hematología y análisis de concordancia interobservador para reforzar la validación por expertos humanos.

4.2.8 Implicaciones para el *pipeline*

Los resultados obtenidos evidenciaron la necesidad de incorporar mecanismos adicionales de refinamiento semántico y validación estructurada dentro del pipeline multimodal. Aunque BLIP v2 mejoró de forma notable respecto a las versiones iniciales, la evaluación multimodal mostró que seguían existiendo limitaciones relevantes en atributos morfológicos finos, especialmente relacionados con citoplasma, granulación y segmentación nuclear. La evaluación con Gemini-3-flash-preview permitió observar que muchas descripciones consideradas morfológicamente adecuadas seguían siendo penalizadas por pequeñas discrepancias semánticas o errores leves de atributos. En la evaluación multimodal, BLIP v2 alcanzó un 56,39 % de descripciones completamente

correctas, mientras que la alta adecuación morfológico-descriptiva se situó en valores próximos al 70 %, indicando que la calidad descriptiva global era superior a la reflejada por las métricas estrictas de exactitud.

En este contexto, las estrategias basadas en BLIP+LoRA representaron una mejora significativa respecto a las versiones anteriores del pipeline. En particular, BLIP+LoRA híbrido fue la configuración que mostró el comportamiento más equilibrado, alcanzando un 58,85 % de correcto estricto, un 83,80 % de correcto ampliado y un 80,95 % de alta adecuación morfológico-descriptiva. Además, obtuvo la mayor accuracy media por atributos morfológicos (86,11 %), reduciendo de forma notable los errores leves de atributos hasta el 24,95 %.

Por su parte, modelos externos como Gemma 3 4B VLM condicionado y Qwen3-VL *fine-tuned* mostraron un comportamiento competitivo en métricas globales. Gemma 3 4B VLM condicionado alcanzó un 94,04 % de correcto ampliado y Qwen3-VL *fine-tuned* un 99,74 %, evidenciando una elevada capacidad para generar descripciones plausibles y lingüísticamente fluidas. Sin embargo, ambos modelos presentaron una mayor variabilidad en atributos morfológicos específicos y un incremento de errores leves, reduciendo su estabilidad estructural frente a BLIP+LoRA híbrido.

En conjunto, los resultados reforzaron la necesidad de un pipeline multietapa basado en generación, refinamiento y validación semántica. Dentro de este esquema, BLIP+LoRA híbrido se identificó como la configuración más equilibrada dentro del marco experimental evaluado, al ofrecer un equilibrio favorable entre precisión morfológica, adecuación morfológico-descriptiva, interpretabilidad y robustez estructural.

4.3 Comparativa entre modelos

Con el objetivo de analizar el impacto de *fine-tuning*, del refinamiento progresivo del *dataset* y de las distintas estrategias de generación utilizadas, se realizó una comparación sistemática entre diferentes configuraciones basadas en modelos visión-lenguaje.

En una primera fase se evaluaron las distintas versiones de BLIP (BLIP base, BLIP v1, BLIP v2 y BLIP v3), con el fin de estudiar la evolución del modelo tras su adaptación al dominio hematológico. Posteriormente, se incorporaron configuraciones basadas en BLIP+LoRA, diferenciando entre una configuración canónica, orientada a la generación de descripciones estructuradas a partir de atributos morfológicos explícitos, y configuraciones libres e híbridas, diseñadas para producir descripciones más naturales y clínicamente interpretables.

BLIP+LoRA constituyó el núcleo principal del pipeline desarrollado en este trabajo, ya que sobre esta arquitectura se construyeron las distintas estrategias de generación, refinamiento y validación morfológica evaluadas. A partir de ella se desarrollaron mecanismos adicionales de normalización terminológica, extracción automática de atributos y postprocesado semántico orientados a mejorar la consistencia descriptiva, reducir errores estructurales y aumentar la fidelidad morfológica de las descripciones generadas.

La evaluación comparativa se organizó en dos etapas. En primer lugar, se analizó la configuración canónica basada en `target_norm_blip_canonico`, utilizada para estudiar la capacidad del modelo para reproducir representaciones estructuradas y controladas de la morfología celular. Posteriormente, se evaluaron las configuraciones basadas en `target_libre_final`, incluyendo BLIP+LoRA libre base, BLIP+LoRA libre mejorado y BLIP+LoRA híbrido, con el objetivo de analizar su capacidad para generar descripciones más naturales manteniendo la precisión morfológica y la calidad descriptiva.

Finalmente, los resultados obtenidos se compararon con modelos multimodales externos, como Gemma 3 4B VLM condicionado y Qwen3-VL fine-tuned, permitiendo contextualizar el rendimiento del pipeline propuesto frente a arquitecturas de referencia más generales.

4.3.1 Metodología de evaluación

La evaluación comparativa se realizó utilizando dos conjuntos de referencia distintos: un target normalizado (`target_norm`), empleado para las estrategias canónicas basadas en atributos estructurados, y un target híbrido (`target_libre_final`), utilizado para las configuraciones orientadas a lenguaje natural.

Inicialmente, se evaluaron BLIP base, BLIP v1, BLIP v2 y BLIP v3, analizando el efecto del *fine-tuning* progresivo sobre la calidad de las *captions* generadas. Posteriormente, se incorporaron BLIP+LoRA en sus distintas variantes (BLIP+LoRA canónico, BLIP+LoRA libre base, BLIP+LoRA libre mejorado y BLIP+LoRA híbrido), así como Gemma 3 4B VLM condicionado y Qwen3-VL fine-tuned.

Para cada instancia del *dataset*, la descripción generada se comparó con el texto objetivo mediante métricas como `exact match`, `overlap`, longitud media de las descripciones y tasa de repetición, permitiendo evaluar coincidencia textual, solapamiento léxico, densidad informativa y redundancia.

Además de las métricas cuantitativas, se incorporó una evaluación semántica automática mediante Gemini-3-

flash-preview, utilizada tanto en configuración unimodal (solo texto) como multimodal (imagen y texto). Esta evaluación permitió analizar no solo la similitud textual, sino también la precisión morfológica y la calidad global de las salidas generadas.

Para los modelos externos, como Gemma 3 4B VLM condicionado y Qwen3-VL fine-tuned, se aplicaron procesos adicionales de normalización y extracción automática de atributos, permitiendo comparar todas las configuraciones dentro de un mismo espacio estructurado basado en rasgos morfológicos.

En conjunto, esta metodología permitió realizar una evaluación integral del pipeline, considerando simultáneamente precisión textual, alineación semántica, adecuación morfológico-descriptiva y estabilidad estructural.

4.3.2 Resultados cuantitativos

En primer lugar, se evaluó la configuración canónica, basada en `target_norm_blip_canonico`, diseñada para generar descripciones estructuradas alineadas con atributos morfológicos explícitos.

Las métricas comparativas entre modelos se calcularon sobre el subconjunto de test estratificado compuesto por 1.543 imágenes, separado del conjunto completo de 16.503 registros válidos. Esta partición se utilizó para mantener una evaluación homogénea entre configuraciones y evitar comparar modelos sobre subconjuntos distintos. La **Tabla 7** muestra los resultados obtenidos para BLIP+LoRA canónico.

Tabla 7. Resultados en configuración canónica. Fuente: Elaboración propia.

	<i>n</i>	<i>BLEU</i>	<i>ROUGE-L</i>	<i>METEOR</i>
	1543	0,0666	0,3412	0,5254
<i>BERTScore</i> <i>F1</i>	<i>Exact Match</i> (%)	<i>Overlap</i>	<i>Repetición</i>	<i>Longitud pred.</i>
0,8882	0,00	0,3368	0,2004	26,88

Los resultados mostraron que BLIP+LoRA canónico mejoró claramente respecto a las versiones iniciales de BLIP en métricas semánticas como ROUGE-L, METEOR y BERTScore F1. La mayor longitud media de las predicciones indicó que el modelo fue capaz de incorporar más contenido morfológico, aunque en algunos casos introdujo redundancia descriptiva. Posteriormente, se evaluó la configuración híbrida (`target_libre_final`), orientada a producir descripciones más naturales y clínicamente interpretables.

En la **Tabla 8** se muestran los resultados cuantitativos globales de los principales modelos evaluados en el *pipeline*. Se incluyen tanto las versiones basadas en BLIP+LoRA como los modelos multimodales externos Gemma 3 y Qwen3-VL, con el objetivo de comparar no solo la calidad textual, sino también la adecuación morfológico-descriptiva y la consistencia morfológica de las descripciones generadas.

Tabla 8. *Comparativa global de modelos evaluados mediante métricas descriptivas y morfológicas. Fuente: Elaboración propia.*

Modelo	n	Corr. estricto	Error leve de atributos	Corr. ampliado	Alta adecuación	Mejora respecto al input	Acc. atributos
<i>BLIP+LoRA libre base</i>	1543	0,06	53,92	53,98	50,36	100,00	54,05
<i>BLIP+LoRA libre mejorado</i>	1543	0,97	34,74	35,71	31,11	31,17	69,34
<i>BLIP+LoRA híbrido</i>	1543	58,85	24,95	83,80	80,95	80,43	86,11
<i>Gemma 3 4B VLM condicionado</i>	1543	39,60	54,44	94,04	69,28	76,02	86,01
<i>Qwen3-VL fine-tuned</i>	1543	44,65	55,09	99,74	74,72	44,91	48,86

Nota. *Corr. = Correcto; Acc. = Accuracy. Los valores se expresan en porcentaje (%) sobre el total de muestras evaluadas (n = 1543). Las abreviaturas se utilizan para mejorar la legibilidad de la tabla.*

Los resultados mostraron diferencias claras entre modelos y estrategias de generación. BLIP+LoRA híbrido fue la configuración que presentó el comportamiento más equilibrado y consistente dentro del pipeline. Este modelo alcanzó el mayor porcentaje de alta adecuación morfológico-descriptiva (80,95 %) y la mejor accuracy media por atributos morfológicos (86,11 %), reduciendo además los errores leves de atributos hasta el 24,95 %. Asimismo, obtuvo un 58,85 % de descripciones completamente correctas en evaluación estricta y un 83,80 % de correcto ampliado, reflejando una elevada estabilidad tanto a nivel semántico como morfológico.

Estos resultados indicaron que BLIP+LoRA híbrido fue capaz de generar descripciones clínicamente interpretables manteniendo simultáneamente coherencia estructural y fidelidad morfológica. Su principal fortaleza no residió únicamente en la calidad lingüística, sino en la capacidad para representar de forma consistente atributos hematológicos complejos, incluso en células con estadios de maduración próximos. Además, el enfoque híbrido permitió reducir ruido semántico, redundancias y errores leves sin perder riqueza descriptiva.

Gemma 3 4B VLM mostró un comportamiento competitivo, alcanzando un 94,04 % de correcto ampliado y una accuracy media por atributos muy próxima a la obtenida por BLIP+LoRA híbrido (86,01 %). Sin embargo, presentó una proporción considerablemente mayor de errores leves de atributos (54,44 %), lo que indicó una menor estabilidad en evaluaciones estrictas. Aunque generó descripciones más fluidas y naturales desde el punto de vista lingüístico, en algunos casos introdujo atributos no claramente respaldados por la imagen o inconsistencias morfológicas finas.

Qwen3-VL *fine-tuned* obtuvo el mayor porcentaje de correcto ampliado (99,74 %), evidenciando una elevada capacidad generativa y una buena coherencia textual global. No obstante, su accuracy media por atributos descendió hasta el 48,86 %, reflejando dificultades importantes en la representación consistente de rasgos morfológicos específicos. Esta diferencia mostró que una elevada plausibilidad semántica global no implicaba necesariamente una representación estructural precisa de la morfología celular.

En conjunto, los resultados mostraron que BLIP+LoRA híbrido ofreció el mejor equilibrio entre precisión estructural, coherencia morfológica, interpretabilidad y robustez semántica, identificándose como la configuración final más equilibrada del pipeline propuesto. Frente a modelos más generativos, mantuvo una representación más estable y controlada de los atributos hematológicos, especialmente relevante para la validación y la generación de descripciones morfológicas fiables. De forma complementaria, se realizó una comparación específica por atributos morfológicos.

La comparación por atributos mostró que BLIP+LoRA híbrido mantuvo el comportamiento más equilibrado entre las distintas dimensiones morfológicas analizadas. Este modelo obtuvo resultados especialmente sólidos en cromatina (97,56 %), tamaño celular (96,04 %) y forma nuclear (91,39 %). Aunque Gemma 3 destacó de forma específica en granulación (87,34 %) y citoplasma (87,13 %), BLIP+LoRA híbrido presentó una representación más homogénea y consistente del conjunto de rasgos hematológicos evaluados. En este trabajo, la selección de la configuración final no se basó en maximizar el rendimiento en un atributo aislado, sino en

mantener un comportamiento estable y equilibrado entre las diferentes características morfológicas analizadas.

Tabla 9. Accuracy por atributo morfológico en los modelos principales. Fuente: Elaboración propia.

<i>Atributo</i>	<i>BLIP+LoRA base (%)</i>	<i>BLIP+LoRA híbrido (%)</i>	<i>Gemma 3 4B (%)</i>	<i>Qwen3-VL fine-tuned (%)</i>
<i>Clase celular</i>	99,35	97,34	99,48	99,61
<i>Tamaño celular</i>	94,82	96,04	92,05	6,04
<i>Forma nuclear</i>	90,25	91,39	92,49	57,19
<i>Cromatina</i>	92,65	97,56	92,99	50,62
<i>Citoplasma</i>	84,38	82,65	87,13	47,27
<i>Granulación</i>	43,94	51,66	87,34	32,40

Estos resultados reforzaron la idea de que el principal valor de BLIP+LoRA híbrido no residió únicamente en generar texto clínicamente plausible, sino en mantener coherencia estructural entre los diferentes atributos morfológicos. Esta estabilidad resultó especialmente relevante en células con estadios de maduración próximos, donde pequeñas discrepancias en cromatina, segmentación nuclear o citoplasma podían modificar la interpretación celular.

Por el contrario, Qwen3-VL fine-tuned mostró una elevada variabilidad entre atributos. Aunque alcanzó métricas globales muy altas en correcto ampliado (99,74 %), su rendimiento descendió notablemente en atributos específicos, especialmente en tamaño celular (6,04 %), granulación (32,40 %) y citoplasma (47,27 %). Estos resultados evidenciaron una menor estabilidad estructural y una representación menos consistente de la morfología celular, a pesar de la buena fluidez textual general de las descripciones generadas.

En conjunto, estos resultados confirmaron que la evaluación basada en atributos permitió caracterizar con mayor precisión las fortalezas y limitaciones reales de cada modelo, aportando una visión más robusta y representativa del comportamiento morfológico de los modelos que las métricas globales tradicionales. Asimismo, reforzaron la elección de BLIP+LoRA híbrido como configuración final del pipeline, al ser el modelo que mantuvo el mejor equilibrio entre coherencia semántica, precisión morfológica y estabilidad estructural.




Figura 7. Comparativa del rendimiento de modelos de visión y lenguaje en métricas morfológicas y de auditoría automática. Fuente: Elaboración propia.

La **Figura 7** muestra una comparativa global del rendimiento de los principales modelos evaluados mediante métricas descriptivas y morfológicas. Los resultados reflejaron diferencias claras entre enfoques. BLIP+LoRA híbrido destacó por mantener uno de los comportamientos más equilibrados entre utilidad descriptiva, precisión estructural y desempeño en atributos morfológicos. Por su parte, Gemma 3 y Qwen3-VL alcanzaron valores elevados en métricas semánticas, aunque presentaron mayor variabilidad en atributos específicos.

La **Figura 8** presenta un heatmap de accuracy por atributo morfológico, permitiendo visualizar de forma detallada el comportamiento de cada modelo en dimensiones concretas. Este análisis evidenció que los errores no se distribuyeron de forma homogénea, sino que se concentraron principalmente en atributos complejos como la granulación y el citoplasma.

En particular, BLIP+LoRA híbrido mostró una representación más estable y equilibrada entre atributos, especialmente en cromatina, tamaño celular y forma nuclear. Gemma 3 obtuvo resultados destacados en granulación y citoplasma, mientras que Qwen3-VL mostró una elevada variabilidad estructural pese a sus altas métricas globales de coherencia textual.

En conjunto, ambas figuras reforzaron la importancia de complementar las métricas globales con evaluaciones específicas por atributos morfológicos, ya que estas permitieron identificar con mayor precisión las fortalezas y limitaciones reales de cada modelo dentro del pipeline propuesto.




Figura 8. Heatmap comparativo del rendimiento por atributo morfológico en los modelos evaluados. Fuente: Elaboración propia.

4.3.3 Análisis cualitativo y comparativa detallada

Además de la comparación cuantitativa, se realizó un análisis cualitativo de ejemplos representativos con el objetivo de estudiar cómo evolucionaban las descripciones generadas a lo largo de las distintas etapas del pipeline. Este análisis permitió valorar no solo si una descripción era globalmente correcta, sino también el nivel de detalle morfológico aportado, su interpretabilidad hematológica y el tipo de errores residuales presentes en cada modelo.

En una primera fase, se compararon BLIP base, BLIP v1 y BLIP v2 para analizar el efecto del *fine-tuning* progresivo sobre el dominio hematológico. BLIP base generó descripciones mayoritariamente genéricas y con escaso contenido clínico, limitándose en muchos casos a identificar la presencia de una célula sanguínea sin describir atributos relevantes. Tras el primer ajuste fino, BLIP v1 introdujo una mejora clara en la estructura descriptiva y en la identificación general de las clases celulares, aunque todavía presentó errores frecuentes de clasificación e incoherencias semánticas.

BLIP v2 mostró una evolución significativa respecto a las versiones anteriores, generando descripciones más completas, específicas y alineadas con la morfología observada. Esta versión redujo notablemente las incoherencias semánticas y mejoró la representación de atributos como cromatina, forma nuclear o relación núcleo/citoplasma. No obstante, siguieron apareciendo errores en atributos morfológicos finos, especialmente

en células con estadios de maduración próximos dentro de la serie mieloide.

Posteriormente, la comparación se amplió a las configuraciones más avanzadas del pipeline: BLIP+LoRA libre mejorado, BLIP+LoRA híbrido, Gemma 3 4B VLM condicionado y Qwen3-VL *fine-tuned*. Esta segunda fase permitió analizar diferencias más sutiles entre modelos generativos y estrategias de refinamiento.

BLIP+LoRA híbrido fue el modelo que mostró el comportamiento más estable y clínicamente interpretable. Las descripciones generadas mantuvieron una estructura implícita basada en atributos hematológicos, reduciendo contradicciones y minimizando la aparición de información no respaldada por la imagen. Además, el postprocesado permitió disminuir redundancias y errores leves sin perder riqueza descriptiva.

Gemma 3 4B VLM generó descripciones más fluidas y naturales desde el punto de vista lingüístico, aportando en algunos casos una representación más rica de determinados atributos morfológicos. Sin embargo, también introdujo ocasionalmente detalles ambiguos o atributos no claramente observables, especialmente en citoplasma y granulación.


Por su parte, Qwen3-VL *fine-tuned* produjo descripciones globalmente plausibles y coherentes a nivel textual, aunque mostró una menor estabilidad en atributos morfológicos concretos. En algunos ejemplos, el modelo incorporó detalles adicionales no presentes en la imagen o generó descripciones menos estructuradas, dificultando la validación basada en atributos.

Cuando los modelos fallaron, los errores se concentraron principalmente en atributos morfológicos finos, como granulación, cromatina, citoplasma y segmentación nuclear, más que en la identificación general de la clase celular. Este comportamiento confirmó que la principal dificultad del problema no residía únicamente en reconocer la célula, sino en describir con precisión y consistencia sus rasgos morfológicos específicos.

Para la comparativa cualitativa se seleccionaron ejemplos representativos en los que pudiera observarse claramente la evolución entre versiones, priorizando casos donde los modelos refinados corrigieron errores presentes en etapas anteriores, así como ejemplos donde persistieron errores morfológicamente relevantes.

Con el fin de ilustrar estas diferencias de forma más clara, la **Figura 9** muestra un ejemplo representativo en el que se comparan las descripciones generadas por distintos modelos a partir de una misma imagen celular.

Imagen celular seleccionada — clase real: band



Modelo	Descripción breve	Comentario
Target experto	Neutrófilo en banda con cromatina condensada y citoplasma azurófilo.	Referencia
BLIP+LoRA híbrido	Identifica banda neutrofílica y citoplasma azurófilo.	Alta concordancia
Gemma 3 4B	Reconoce cromatina condensada y citoplasma amplio.	Concordancia parcial
Qwen3-VL	Detecta núcleo en banda y gránulos azurófilos.	Concordancia parcial

Figura 9. Comparativa cualitativa de descripciones generadas por distintos modelos a partir de una misma imagen celular. Fuente: Elaboración propia.

En este ejemplo, todos los modelos identificaron correctamente la célula en banda y describieron los principales rasgos morfológicos observables. No obstante, se apreciaron diferencias en el nivel de detalle y en la estructuración de la información. BLIP+LoRA híbrido proporcionó la descripción más completa, incorporando atributos adicionales como la relación núcleo/citoplasma y la morfología nuclear, mientras que Gemma 3 generó una redacción más concisa y fluida. Por su parte, Qwen3-VL produjo una descripción globalmente correcta, aunque con menor riqueza descriptiva y cierta variabilidad en algunos atributos.

En conjunto, el análisis cualitativo confirmó que los modelos refinados mejoraron claramente respecto a BLIP base, aunque también evidenció que las métricas globales no capturan completamente todos los matices clínicos y morfológicos de las descripciones generadas. Este ejemplo ilustra cómo modelos con resultados globales similares pueden diferir en la cantidad, precisión y organización de la información morfológica proporcionada.

4.3.4 Limitaciones observadas

A pesar de las mejoras obtenidas a lo largo del pipeline, las descripciones generadas siguieron presentando limitaciones relevantes en atributos morfológicos finos. Aunque el *fine-tuning* de BLIP y las etapas posteriores

de refinamiento mejoraron claramente la calidad respecto al modelo base, persistieron errores relacionados con citoplasma, granulación, cromatina y segmentación nuclear, especialmente en células con estadios de maduración próximos dentro de la serie mieloide.

En BLIP v2, estas limitaciones se observaron principalmente en confusiones entre mielocitos y metamielocitos, así como entre células en banda y neutrófilos segmentados. La evaluación multimodal mostró además que algunas descripciones textualmente coherentes presentaban discrepancias al contrastarse directamente con la imagen, evidenciando que la alineación imagen-texto continuó siendo un reto abierto.

La incorporación de BLIP+LoRA híbrido permitió reducir de forma significativa los errores globales y mejorar la consistencia estructural, alcanzando una accuracy media por atributos del 86,11 %. Sin embargo, siguieron apareciendo errores leves en atributos específicos, especialmente relacionados con granulación y citoplasma, indicando que incluso la configuración final mantenía limitaciones en la interpretación de rasgos visuales complejos.

En cuanto a los modelos externos, Gemma 3 mejoró la fluidez y naturalidad lingüística de las descripciones, aunque presentó una elevada proporción de errores leves de atributos (54,44 %), introduciendo ocasionalmente información no claramente observable. Por su parte, Qwen3-VL *fine-tuned* obtuvo métricas globales muy altas en correcto ampliado (99,74 %), pero mostró menor estabilidad estructural y menor precisión en atributos morfológicos específicos. Asimismo, persistieron algunos errores lingüísticos, como repeticiones y redundancias léxicas, especialmente en descripciones relacionadas con cromatina. Aunque estos artefactos no impedían la comprensión global, afectaban a la claridad y calidad final de las *captions* generadas.

Desde el punto de vista cuantitativo, se observó que métricas como *exact match* no reflejaban completamente la mejora semántica de los modelos, mientras que métricas basadas en *overlap*, evaluación multimodal y accuracy por atributos proporcionaron una representación más precisa de su comportamiento morfológico-descriptivo. En conjunto, los resultados indicaron que ningún modelo optimizaba simultáneamente todas las dimensiones del problema, por lo que la combinación de generación multimodal, refinamiento semántico, validación basada en atributos y BLIP+LoRA híbrido resultó necesaria para obtener descripciones más precisas, coherentes y morfológicamente adecuadas.

4.4 Comparativa global entre modelos y estrategias de generación

4.4.1 Configuraciones evaluadas

Con el objetivo de analizar el impacto de distintas estrategias de generación y refinamiento textual, se evaluaron múltiples configuraciones basadas en modelos visión-lenguaje.

En una primera fase se analizaron BLIP base y sus versiones fine-tuned (BLIP v1 y BLIP v2), permitiendo estudiar la evolución del modelo tras su adaptación progresiva al dominio hematológico. Posteriormente, se incorporaron distintas variantes de BLIP+LoRA, incluyendo BLIP+LoRA canónico, BLIP+LoRA libre base, BLIP+LoRA libre mejorado y BLIP+LoRA híbrido, con el objetivo de evaluar diferentes estrategias de generación, desde representaciones estructuradas basadas en atributos morfológicos hasta descripciones más naturales y clínicamente interpretables. Finalmente, se incorporaron modelos multimodales externos, como Gemma 3 4B VLM condicionado y Qwen3-VL fine-tuned, utilizados como referencia para contextualizar el rendimiento del pipeline propuesto frente a arquitecturas más generales.

4.4.2 Diferencias entre estrategias de generación

Las configuraciones evaluadas respondieron a enfoques complementarios dentro del pipeline multimodal desarrollado. Mientras algunas estrategias priorizaron el control estructural de la descripción, otras se centraron en mejorar la naturalidad lingüística o la capacidad generativa multimodal.

BLIP+LoRA canónico se diseñó para generar descripciones estructuradas a partir de atributos morfológicos explícitos, favoreciendo estabilidad estructural e interpretabilidad clínica. Aunque redujo inconsistencias semánticas, en algunos casos produjo descripciones más rígidas. Por el contrario, BLIP+LoRA libre base y BLIP+LoRA libre mejorado generaron textos más naturales y variados, pero también más propensos a redundancias y errores leves en atributos morfológicos. Para equilibrar naturalidad y consistencia descriptiva, se desarrolló posteriormente BLIP+LoRA híbrido, que redujo ruido semántico y mejoró la coherencia estructural sin perder fluidez textual.

Además, se evaluaron modelos multimodales externos como Gemma 3 4B VLM condicionado y Qwen3-VL fine-tuned. Estos modelos mostraron una elevada capacidad generativa y produjeron descripciones más naturales y plausibles desde el punto de vista lingüístico. No obstante, presentaron una menor estabilidad estructural y una mayor variabilidad en atributos morfológicos finos, especialmente en tareas relacionadas con

granulación, cromatina y segmentación nuclear.

En conjunto, las distintas estrategias evidenciaron que la calidad del pipeline no dependía únicamente de la fluidez del texto generado, sino también de la capacidad para preservar coherencia morfológica y consistencia descriptiva entre imagen y descripción.

4.4.3 Comparación a nivel de atributos morfológicos

Para comparar de forma homogénea modelos con salidas heterogéneas, todas las descripciones generadas fueron transformadas en representaciones estructuradas basadas en atributos morfológicos. Este proceso permitió proyectar *captions* libres, texto refinado y salidas multimodales sobre un mismo espacio semántico, facilitando la comparación directa entre configuraciones.

Los resultados mostraron diferencias claras entre estrategias de generación. BLIP+LoRA híbrido fue la configuración que mantuvo el comportamiento más equilibrado entre los distintos atributos analizados. El modelo alcanzó una accuracy media del 86,11 %, destacando especialmente en cromatina, tamaño celular y forma nuclear, además de reducir significativamente los errores leves de atributos.

BLIP+LoRA canónico mostró una elevada estabilidad estructural y facilitó la representación consistente de atributos clínicos. Sin embargo, sus descripciones tendieron a ser más rígidas y menos naturales que las generadas mediante estrategias libres.

Por su parte, BLIP+LoRA libre mejorado mejoró la expresividad y naturalidad del lenguaje, aunque introdujo una mayor variabilidad semántica y una menor precisión en algunos atributos específicos. La estrategia híbrida permitió corregir gran parte de estas limitaciones, mejorando simultáneamente coherencia estructural y naturalidad descriptiva.

Gemma 3 4B VLM condicionado presentó una elevada calidad lingüística y obtuvo resultados competitivos en atributos relacionados con granulación y citoplasma. No obstante, mostró una mayor tendencia a introducir discrepancias leves entre texto e imagen, reduciendo su estabilidad en evaluaciones estrictas.

Qwen3-VL fine-tuned alcanzó métricas globales muy elevadas en correcto ampliado, reflejando una gran capacidad generativa y buena coherencia textual global. Sin embargo, la precisión descendió notablemente al analizar atributos concretos, especialmente en tamaño celular, cromatina y citoplasma, evidenciando una menor consistencia estructural.

En conjunto, el análisis por atributos permitió caracterizar con mayor precisión las fortalezas y limitaciones reales de cada modelo, aportando una evaluación más robusta que las métricas globales tradicionales.

4.4.4 Comparación global de errores

El análisis cualitativo y cuantitativo de errores permitió identificar patrones diferenciados según la estrategia utilizada.

BLIP base generó principalmente descripciones genéricas y con escaso contenido hematológico, confirmando las limitaciones de los modelos generalistas de *captioning* cuando se aplican directamente sobre imágenes biomédicas. Aunque las *captions* eran visualmente plausibles, la mayoría carecía de información relevante sobre cromatina, granulación o segmentación nuclear.

Las versiones *fine-tuned* de BLIP mejoraron progresivamente la calidad semántica de las descripciones. BLIP v1 introdujo una estructura descriptiva más consistente, aunque todavía mantuvo errores de clasificación e incoherencias semánticas. BLIP v2 redujo gran parte de estos problemas y mejoró la representación de atributos morfológicos, aunque persistieron limitaciones en rasgos finos relacionados con citoplasma, granulación y diferenciación entre estadios próximos de maduración celular.

La incorporación de BLIP+LoRA permitió mejorar de forma notable la estabilidad estructural de las *captions*. En particular, BLIP+LoRA híbrido redujo significativamente los errores de incoherencia semántica y las repeticiones léxicas, manteniendo una representación más consistente de los atributos hematológicos relevantes.

En los modelos externos se observaron limitaciones diferentes. Gemma 3 4B VLM condicionado produjo descripciones más fluidas y naturales, aunque ocasionalmente introdujo detalles no claramente observables en la imagen original. Por su parte, Qwen3-VL fine-tuned mostró una elevada capacidad generativa, pero también una mayor variabilidad semántica y menor estabilidad en atributos morfológicos específicos.

De forma general, los errores más frecuentes se concentraron en atributos finos, especialmente granulación, cromatina, citoplasma y segmentación nuclear. Estas limitaciones fueron particularmente relevantes en células de la serie mieloide, donde pequeñas variaciones morfológicas pueden modificar la interpretación clínica.

4.4.5 Discusión global

Los resultados mostraron que la generación automática de descripciones hematológicas requiere equilibrar precisión morfológica, consistencia descriptiva y naturalidad lingüística. Las configuraciones canónicas ofrecieron mayor estabilidad estructural, mientras que las estrategias libres y los modelos multimodales externos generaron descripciones más fluidas, aunque con una mayor variabilidad en atributos específicos.

Entre todas las configuraciones evaluadas, BLIP+LoRA híbrido fue la que mostró el comportamiento más equilibrado, combinando una elevada precisión morfológica con descripciones clínicamente interpretables y consistentes.

En conjunto, los resultados confirmaron que la calidad de un sistema de generación biomédica no depende únicamente de la fluidez textual, sino también de su capacidad para preservar de forma consistente la relación entre imagen, atributos morfológicos y significado clínico.

Capítulo 5

5. Discusión

Los resultados muestran que los modelos visión-lenguaje generalistas presentan limitaciones cuando se aplican al dominio hematológico, especialmente en la representación de atributos morfológicos finos y en la diferenciación entre estadios celulares próximos. El fine-tuning mejoró la coherencia semántica y la calidad de las descripciones, aunque persistieron dificultades en características de alta granularidad.

Uno de los principales hallazgos fue la utilidad de incorporar conocimiento experto mediante atributos estructurados y normalización terminológica, favoreciendo una representación más consistente e interpretable de la información morfológica. Asimismo, los resultados evidenciaron que la mejora del sistema depende de la combinación de generación multimodal, refinamiento semántico y validación estructurada.

La comparación entre BLIP+LoRA, Gemma 3 y Qwen3-VL mostró diferentes compromisos entre precisión morfológica, estabilidad estructural y fluidez lingüística. En conjunto, BLIP+LoRA con postprocesado conservador presentó el comportamiento más equilibrado.

Por otra parte, la evaluación puso de manifiesto las limitaciones de las métricas basadas exclusivamente en coincidencia textual y la importancia de incorporar evaluación semántica, análisis por atributos y auditoría multimodal para valorar correctamente la calidad de las descripciones generadas. Los resultados también confirmaron que la alineación imagen-texto continúa siendo uno de los principales desafíos en sistemas multimodales biomédicos.

Estos resultados sugieren que, en dominios biomédicos de alta granularidad, la evaluación de modelos visión-lenguaje no debería depender únicamente de métricas globales de similitud textual o plausibilidad lingüística, sino de mecanismos explícitos de validación por atributos y, en fases posteriores, de revisión por expertos humanos.

Entre las principales limitaciones del estudio destacan la ausencia de validación por expertos humanos, la dificultad de modelar atributos hematológicos muy específicos y el tamaño limitado de la muestra disponible. Por tanto, los resultados deben interpretarse como una evaluación automática y comparativa de estrategias de generación morfológica, no como una validación clínica definitiva del sistema.

Capítulo 6

6. Valoración económica

La estimación distingue entre costes directos desembolsados durante el desarrollo académico del TFM y una valoración equivalente del trabajo realizado. Dado que parte de los recursos fueron gratuitos, open source o facilitados mediante créditos, el coste directo no refleja el valor económico completo del proyecto.

Tabla 10. Estimación de costes asociados al desarrollo del proyecto. Fuente: Elaboración propia.

<i>Concepto</i>	<i>Descripción</i>	<i>Coste estimado (€)</i>
Computación GPU y APIs	Modal, Colab, Gemini, Fireworks u otros créditos equivalentes	100–500
Almacenamiento y repositorio	GitHub, Hugging Face, Google Drive/GCP en uso académico	0–100
Desarrollo e implementación	300–450 h de trabajo técnico/académico estimadas	4.500–9.000
Revisión, dirección y supervisión	Reuniones, revisión metodológica y orientación técnica	500–1.500
Documentación, análisis y redacción	Preparación de memoria, figuras, métricas y resultados	1.000–2.500
Coste directo desembolsado	Coste efectivamente asumido en el TFM	25–105
Coste equivalente estimado	Valor aproximado si se presupuestara como proyecto	6.000–13.500

Capítulo 7

7. Conclusiones y trabajos futuros

7.1. Conclusiones

El objetivo de este trabajo ha sido mejorar la calidad de las descripciones morfológicas generadas a partir de imágenes de células sanguíneas mediante la integración de modelos visión-lenguaje y conocimiento experto estructurado.

Los resultados muestran que la adaptación al dominio hematológico resulta determinante para mejorar la calidad de las descripciones generadas. En este contexto, BLIP+LoRA se identifica como la configuración más equilibrada dentro del marco experimental desarrollado.

Desde el punto de vista metodológico, se evaluaron dos estrategias complementarias. La estrategia canónica permitió analizar la capacidad del modelo para alinearse con descripciones estructuradas y mejorar métricas semánticas como BLEU y ROUGE-L. Por su parte, la estrategia libre produjo descripciones más naturales y fluidas, manteniendo la información morfológica esencial. Aunque ambas aproximaciones presentan ventajas específicas, la estrategia libre mostró un equilibrio favorable entre consistencia morfológica y calidad lingüística.

Asimismo, los resultados ponen de manifiesto la utilidad de incorporar conocimiento experto mediante atributos estructurados y normalización terminológica para mejorar la coherencia de las descripciones y facilitar su evaluación automática. Del mismo modo, modelos complementarios como Gemma 3 y Qwen3-VL aportan valor en tareas de refinamiento lingüístico y evaluación multimodal, aunque sin superar el rendimiento global de BLIP+LoRA.

En conjunto, los resultados sugieren que la combinación de *fine-tuning* eficiente, conocimiento estructurado y validación sistemática permite desarrollar un pipeline reproducible y robusto para la generación automática de descripciones morfológicas en hematología. No obstante, persisten desafíos relacionados con la representación de atributos morfológicos finos, que constituyen una línea de investigación relevante para futuros desarrollos.

7.2. Líneas de futuro

A partir de los resultados obtenidos, se identifican diversas líneas de trabajo futuro orientadas a mejorar y ampliar el enfoque propuesto.

Como línea prioritaria, se plantea incorporar una validación por hematólogos o citomorfólogos sobre una muestra estratificada, permitiendo estimar concordancia interobservador y comparar la evaluación humana con la auditoría automática realizada por los modelos multimodales.

Entre otras líneas de desarrollo destacan la mejora de la extracción automática de atributos morfológicos complejos, la exploración de modelos multimodales más especializados para dominios biomédicos, el desarrollo de una integración end-to-end del pipeline y la incorporación de modelos avanzados de razonamiento para reforzar la coherencia entre imagen y descripción. Asimismo, la metodología podría extenderse a otros ámbitos de la imagen médica.

7.3. Seguimiento de la planificación

En general, la planificación se ha seguido adecuadamente, con algunos ajustes durante el desarrollo. La metodología permitió estructurar el trabajo en fases claras de análisis, diseño del pipeline, generación, normalización y evaluación. Durante el proceso se incorporaron modelos adicionales como Gemma 3 y Qwen3-VL, así como evaluadores automáticos como Gemini-3-flash-preview, no previstos inicialmente. Estas incorporaciones mejoraron la calidad del análisis, permitieron una evaluación más robusta del sistema y ampliaron el alcance experimental previsto en la planificación original.

7.4 Impacto ético, social y de sostenibilidad

Desde una perspectiva ético-social, este trabajo contribuye al desarrollo de herramientas de apoyo al análisis clínico, mejorando la eficiencia diagnóstica. No obstante, el sistema se plantea como complemento al criterio médico y requiere validación por expertos en entornos reales.

En términos de sostenibilidad, el uso de técnicas eficientes como LoRA reduce el coste computacional frente a enfoques tradicionales. Aunque no se identifican impactos negativos relevantes, la aplicación de IA en el ámbito biomédico requiere evaluación continua de su fiabilidad e implicaciones éticas.

Glosario

Término	Definición
Alineación imagen-texto	Correspondencia semántica entre imagen y descripción.
Auditoría semántica	Evaluación automática de descripciones para detectar errores o incoherencias.
Auditoría multimodal	Evaluación conjunta de imagen y texto para analizar su coherencia semántica y morfológica.
CLIPScore	Métrica que evalúa la similitud entre imagen-texto utilizando modelos multimodales.
BLIP (Bootstrapping Language-Image Pretraining)	Modelo visión-lenguaje para generar descripciones automáticas a partir de imágenes.
BLIP + LoRA	modelo BLIP adaptado mediante LoRA para la generación de descripciones morfológicas.
Coherencia semántica	Consistencia entre imagen y descripción textual.
Consistencia morfológica	Grado en que las descripciones respetan las características biológicas esperadas de cada tipo celular.
<i>Dataset</i>	Conjunto de datos utilizado para entrenamiento, validación o evaluación de modelos.
<i>Dataset</i> multimodal	<i>Dataset</i> que integra imágenes, texto u otras modalidades para aprendizaje conjunto.
<i>Dataset</i> auditado	<i>Dataset</i> validado mediante reglas estructurales, métricas y evaluación semántica.
<i>Dataset</i> canónico	Representación estructurada del <i>dataset</i> basada en atributos morfológicos y vocabulario controlado.
<i>Dataset</i> libre	Representación del <i>dataset</i> en lenguaje natural, sin restricciones estructurales estrictas.
<i>Dataset</i> desbalanceado	<i>Dataset</i> con distribución desigual de muestras entre clases.
Diccionario controlado	Conjunto de términos definidos para unificar descripciones y evitar ambigüedades.
Evaluación por atributos	Análisis del rendimiento sobre atributos morfológicos específicos.
Extracción de atributos morfológicos	Identificación automática de características morfológicas relevantes.
<i>Fine-tuning</i> (ajuste fino)	Adaptación de un modelo preentrenado a una tarea específica mediante

	entrenamiento adicional.
Fireworks (Fireworks AI)	Plataforma de inferencia y entrenamiento para <i>fine-tuning</i> y evaluación de modelos multimodales.
Gemma (Gemma 3)	Modelo de lenguaje utilizado para refinamiento textual de descripciones.
Gemini-3-flash-preview	Modelo multimodal para auditoría semántica automática de coherencia imagen-texto.
LoRA (Low-Rank Adaptation)	Técnica eficiente de <i>fine-tuning</i> con bajo coste computacional.
Métricas NLP	Métricas utilizadas para evaluar texto generado automáticamente.
Modelo visión-lenguaje (VLM)	Modelo que integra información visual y textual para tareas multimodales.
Modelo multimodal	Modelo capaz de procesar e integrar múltiples modalidades de datos.
Normalización terminológica	Proceso de estandarización del vocabulario para reducir la variabilidad léxica.
Pipeline	Conjunto organizado de etapas para procesar y validar datos.
Pipeline multimodal	<i>Pipeline</i> que integra procesamiento visual y textual en diferentes etapas
Postprocesado canónico	Refinamiento basado en reglas estructuradas y atributos morfológicos definidos.
Postprocesado libre	Refinamiento sin restricciones estructurales.
Qwen3-VL	Modelo multimodal avanzado utilizado como referencia (<i>benchmark</i>) para evaluar la generación de descripciones imagen-texto en comparación con otros enfoques.
Reproducibilidad	Obtención de los mismos resultados en las mismas condiciones.
Robustez	Capacidad del modelo para mantener su rendimiento ante variaciones en los datos.
Trazabilidad	Capacidad de rastrear el origen y las transformaciones de los datos.
Vision Transformer (ViT)	Arquitectura de visión utilizada para extraer características visuales mediante mecanismos de atención.

Bibliografia

- Abbas, Q., Jeong, W., & Lee, S. W. (2025). Explainable AI in clinical decision support systems: A meta-analysis of methods, applications, and usability challenges. *Healthcare*, 13(17), 2154. <https://doi.org/10.3390/healthcare13172154>
- Acevedo, A., Merino, A., Alf  rez, S., Molina,   ., Bold  , L., & Rodellar, J. (2020). A dataset for microscopic peripheral blood cell images for development of automatic recognition systems. *Data in Brief*, 30, 105474.
- Ahadian, P., Xu, W., Liu, D., & Guan, Q. (2026). Ethics of trustworthy AI in healthcare: Challenges, principles, and practical pathways. *Neurocomputing*, 661, 131942. <https://doi.org/10.1016/j.neucom.2025.131942>
- Bain, B. J. (2019). *Blood cells: A practical guide* (5th ed.). Wiley-Blackwell.
- Bai, S., Cai, Y., Chen, R., Chen, K., Chen, X., Cheng, Z., Deng, L., Ding, W., Gao, C., Ge, C., Ge, W., Guo, Z., Huang, Q., Huang, J., Huang, F., Hui, B., Jiang, S., Li, Z., Li, M., ... Zhu, K. (2025). Qwen3-VL technical report [Preprint]. arXiv. <https://doi.org/10.48550/arXiv.2511.21631>
- Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D. M., Wu, J., Winter, C., & Amodei, D. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems*, 33, 1877–1901.
- Da Rin, G., Seghezzi, M., Padoan, A., Pajola, R., Bengiamo, A., Di Fabio, A. M., Dima, F., Fanelli, A., Francione, S., Germagnoli, L., Lorubbio, M., Marzoni, A., Pipitone, S., Rolla, R., Bagorria Vaca, M. D. C., Bartolini, A., Bonato, L., Sciacovelli, L., & Buoro, S. (2022). Multicentric evaluation of the variability of digital morphology performances also respect to the reference methods by optical microscopy. *International Journal of Laboratory Hematology*, 44(6), 1040–1049. <https://doi.org/10.1111/ijlh.13943>
- Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., et al. (2021). *An image is worth 16×16 words: Transformers for image recognition at scale*. arXiv. <https://doi.org/10.48550/arXiv.2010.11929>

- Gemma Team, Kamath, A., Ferret, J., Pathak, S., Vieillard, N., Merhej, R., Perrin, S., Matejovicova, T., Ramé, A., Rivière, M., Rouillard, L., Mesnard, T., Cideron, G., Grill, J.-B., Ramos, S., Yvinec, E., Casbon, M., Pot, E., Penchev, I., ... Hussenot, L. (2025). Gemma 3 technical report [Preprint]. arXiv. <https://doi.org/10.48550/arXiv.2503.19786>
- Google AI for Developers. (2026). Gemini 3 Flash Preview. <https://ai.google.dev/gemini-api/docs/models/gemini-3-flash-preview>
- Gunes, E. K. (2025). Artificial intelligence in hematology: Current trends and application areas. *Annals of Hematology*, 104, 6033–6043. <https://doi.org/10.1007/s00277-025-06706-2>
- Hasanzadeh, F., Josephson, C. B., Waters, G., Adedinsewo, D., Azizi, Z., & White, J. A. (2025). Bias recognition and mitigation strategies in artificial intelligence healthcare applications. *npj Digital Medicine*, 8, 154. <https://doi.org/10.1038/s41746-025-01503-7>
- Hatamizadeh, A., Nath, V., Tang, Y., Yang, D., Roth, H. R., & Xu, D. (2022). *UNETR: Transformers for 3D medical image segmentation*. arXiv. <https://doi.org/10.48550/arXiv.2103.10504>
- Howard, J., & Ruder, S. (2018). Universal language model fine-tuning for text classification. *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics*, 328–339. <https://doi.org/10.18653/v1/P18-1031>
- Johnson, A. E. W., Pollard, T. J., Berkowitz, S. J., Greenbaum, N. R., Lungren, M. P., Deng, C. Y., et al. (2019). MIMIC-CXR, a de-identified publicly available database of chest radiographs with free-text reports. *Scientific Data*, 6, 317. <https://doi.org/10.1038/s41597-019-0322-0>
- Joseph, J. (2025). Algorithmic bias in public health AI: A silent threat to equity in low-resource settings. *Frontiers in Public Health*, 13, 1643180. <https://doi.org/10.3389/fpubh.2025.1643180>
- Karpathy, A., & Fei-Fei, L. (2015). Deep visual-semantic alignments for generating image descriptions. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 3128–3137. <https://doi.org/10.1109/CVPR.2015.7298932>
- Kim, H., Hur, M., d’Onofrio, G., & Zini, G. (2025). Real-world application of digital morphology analyzers:

- Practical issues and challenges in clinical laboratories. *Diagnostics*, 15(6), 677. <https://doi.org/10.3390/diagnostics15060677>
- Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. *Advances in Neural Information Processing Systems*, 25, 1097–1105.
- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436–444. <https://doi.org/10.1038/nature14539>
- Li, J., Li, D., Xiong, C., & Hoi, S. (2022). BLIP: Bootstrapping language-image pre-training for unified vision-language understanding and generation. In *Proceedings of the 39th International Conference on Machine Learning* (pp. 12888–12900).
- Litjens, G., Kooi, T., Bejnordi, B. E., Setio, A. A. A., Ciompi, F., Ghafoorian, M., et al. (2017). A survey on deep learning in medical image analysis. *Medical Image Analysis*, 42, 60–88. <https://doi.org/10.1016/j.media.2017.07.005>
- Matek, C., Schwarz, S., Spiekermann, K., & Marr, C. (2019). Human-level recognition of blast cells in acute myeloid leukemia with convolutional neural networks. *Nature Machine Intelligence*, 1(11), 538–544. <https://doi.org/10.1038/s42256-019-0101-9>
- Merino, A. (2020). *Atlas de citología de sangre periférica*. Grupo Español de Citología Hematológica (GECH), Sociedad Española de Hematología y Hemoterapia.
- Ohsaka, A. (2020). Artificial intelligence (AI) and hematological diseases: Establishment of a peripheral blood convolutional neural network (CNN)-based digital morphology analysis system. *Rinsho Ketsueki*, 61(5), 564–573. <https://doi.org/10.11406/rinketsu.61.564>
- Pan, S. J., & Yang, Q. (2010). A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering*, 22(10), 1345–1359. <https://doi.org/10.1109/TKDE.2009.191>
- Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., et al. (2021). *Learning transferable visual models from natural language supervision*. arXiv. <https://doi.org/10.48550/arXiv.2103.00020>
- Roberts, M., Driggs, D., Thorpe, M., Gilbey, J., Yeung, M., Ursprung, S., Aviles-Rivero, A., Etmann, C.,

- McCague, C., Beer, L., Weir-McCall, J., Teng, Z., Gkrania-Klotsas, E., AIX-COVNET, Rudd, J. H. F., Sala, E., & Schönlieb, C.-B. (2021). Common pitfalls and recommendations for using machine learning to detect and prognosticate for COVID-19 using chest radiographs and CT scans. *Nature Machine Intelligence*, 3,199–217. <https://doi.org/10.1038/s42256-021-00307-0>
- Sasada, K., Yamamoto, N., Masuda, H., Tanaka, Y., Ishihara, A., Takamatsu, Y., et al. (2018). Inter-observer variance and the need for standardization in the morphological classification of myelodysplastic syndrome. *Leukemia Research*, 69, 54–59. <https://doi.org/10.1016/j.leukres.2018.04.003>
- Topol, E. J. (2019). *Deep medicine: How artificial intelligence can make healthcare human again*. Basic Books.
- Unsloth AI. (2024). *Efficient fine-tuning methods*. GitHub. <https://github.com/unslothai/unsloth>
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30.
- Vinyals, O., Toshev, A., Bengio, S., & Erhan, D. (2015). Show and tell: A neural image caption generator. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 3156–3164. <https://doi.org/10.1109/CVPR.2015.7298935>

Apéndice

Anexo 1. *Pipeline* completo del sistema

El *pipeline* se estructura como un flujo modular para el análisis morfológico de células sanguíneas, abarcando desde la adquisición de imágenes hasta la generación, refinamiento y evaluación de descripciones morfológicas.

Las imágenes microscópicas se procesan mediante un modelo ViT para su clasificación y validación. A continuación, un modelo de visión y lenguaje (BLIP) genera descripciones iniciales, que posteriormente se transforman en representaciones estructuradas mediante normalización terminológica y extracción de atributos morfológicos.

El sistema incorpora conocimiento experto y aplica *fine-tuning* (BLIP+LoRA) para su adaptación al dominio hematológico. Las descripciones se refinan mediante postprocesado y se comparan con modelos multimodales como Gemma y Qwen3-VL.

La evaluación combina análisis semántico mediante Gemini-3-flash-preview con métricas cuantitativas (BLEU, ROUGE, METEOR y BERTScore), tanto a nivel global como por atributo. Finalmente, los resultados se organizan en una estructura unificada que garantiza la trazabilidad y la reproducibilidad del proceso.

Anexo 2. Definición formal de métricas e indicadores de evaluación

Este anexo define formalmente las métricas utilizadas para evaluar la calidad textual, semántica, estructural y morfológica de las descripciones generadas por los modelos visión-lenguaje. Dado que las salidas generadas pueden diferir en estilo, longitud y grado de estructuración, se empleó una combinación de métricas complementarias. Las métricas NLP permitieron estimar similitud léxica y semántica con respecto a descripciones de referencia; las métricas estructurales permitieron evaluar cobertura y consistencia de atributos morfológicos; y la auditoría multimodal permitió valorar la correspondencia entre imagen, descripción y atributos hematológicos.

Ninguna métrica se interpretó de forma aislada. En particular, las métricas de similitud textual como BLEU o ROUGE pueden penalizar formulaciones alternativas aunque sean morfológicamente correctas, mientras que métricas semánticas como BERTScore pueden sobrestimar descripciones lingüísticamente plausibles pero incompletas desde el punto de vista morfológico. Por ello, la evaluación final combinó métricas textuales, auditoría automática y análisis por atributos.

A. BLEU

BLEU mide la coincidencia de n-gramas entre una descripción generada y una descripción de referencia. Para cada orden de n-grama se calcula una precisión modificada y se combina con una penalización por brevedad.

$$BLEU = BP \cdot \exp \left(\sum_{n=1}^N w_n \log p_n \right)$$

donde P_n es la precisión modificada de n-gramas de orden n , w_n es el peso asignado a cada orden de n-grama y es la penalización por brevedad. En este trabajo, BLEU se interpretó como una medida de coincidencia léxica, no como una medida directa de corrección clínica.

B. ROUGE-L

ROUGE-L evalúa la similitud entre dos textos mediante la longitud de la subsecuencia común más larga. Esta métrica resulta útil para estimar si la descripción generada conserva parte de la estructura informativa de la referencia.

$$R_{LCS} = \frac{LCS(X, Y)}{m}$$

$$P_{LCS} = \frac{LCS(X, Y)}{n}$$

$$ROUGE-L = \frac{(1 + \beta^2) R_{LCS} P_{LCS}}{R_{LCS} + \beta^2 P_{LCS}}$$

donde LCS representa la longitud de la subsecuencia común más larga entre la referencia y la predicción es la longitud de la referencia y n la longitud de la predicción.

C. METEOR

METEOR combina precisión y exhaustividad entre la descripción generada y la referencia, incorporando coincidencias exactas y variantes léxicas. En términos generales, se calcula a partir de una media armónica ponderada de precisión y recall, penalizando alineaciones fragmentadas.

$$F_{mean} = \frac{10PR}{R + 9P}$$

$$METEOR = F_{mean}(1 - Penalty)$$

donde P representa la precisión, R el recall y $Penalty$ penaliza alineaciones poco compactas o fragmentadas.

D. BERTScore

BERTScore evalúa la similitud semántica entre una descripción generada y una referencia utilizando *embeddings* contextualizados. A diferencia de métricas basadas exclusivamente en coincidencia léxica, permite capturar equivalencias semánticas entre formulaciones diferentes.

Para cada token de la descripción generada se busca el token más similar de la referencia mediante similitud coseno:

$$P_{BERT} = \frac{1}{|\hat{x}|} \sum_{\hat{x}_i \in \hat{x}} \max_{x_j \in x} \cos(e_{\hat{x}_i}, e_{x_j})$$

$$R_{BERT} = \frac{1}{|x|} \sum_{x_j \in x} \max_{\hat{x}_i \in \hat{x}} \cos(e_{x_j}, e_{\hat{x}_i})$$

$$F1_{BERT} = 2 \cdot \frac{P_{BERT} R_{BERT}}{P_{BERT} + R_{BERT}}$$

donde x es la referencia, $\hat{x}$ la descripción generada y e representa los *embeddings* contextualizados de cada token.

E. CLIPScore

CLIPScore mide la alineación entre una imagen y una descripción textual mediante la similitud entre sus *embeddings* multimodales.

$$CLIPScore = \max(0, 100 \cdot \cos(E_I, E_T))$$

donde E_I es el *embedding* de la imagen y E_T el *embedding* del texto generado. En este trabajo, esta métrica se interpretó como una medida de correspondencia imagen-texto, no como una validación morfológica completa.

F. Cobertura de atributos morfológicos

La cobertura de atributos mide la proporción de atributos morfológicos esperados que aparecen explícitamente o son recuperables en la descripción generada.

$$Cobertura = \frac{|A_{detectados}|}{|A_{esperados}|} \times 100$$

donde $A_{detectados}$ es el conjunto de atributos identificados en la descripción generada y $A_{representados}$ es el conjunto de atributos esperados según el esquema morfológico de referencia.

G. Tasa de inconsistencias estructurales

La tasa de inconsistencias estructurales mide la proporción de registros que incumplen al menos una regla de validación definida en el *pipeline*.

$$Tasa\ de\ inconsistencias = \frac{N_{registros\ con\ errores}}{N_{registros\ evaluados}} \times 100$$

Esta métrica permite estimar la calidad estructural del *dataset* y detectar problemas como valores fuera del vocabulario permitido, atributos ausentes o combinaciones morfológicas no plausibles.

H. Correcto estricto

El correcto estricto corresponde al porcentaje de descripciones clasificadas como completamente correctas por el auditor automático multimodal.

$$Correcto\ estricto = \frac{N_{correcto}}{N_{total}} \times 100$$

Esta métrica es conservadora, ya que no considera aceptables las descripciones con errores leves de atributos.

I. Correcto ampliado

El correcto ampliado considera como aceptables tanto las descripciones clasificadas como correctas como aquellas que presentan únicamente errores leves de atributos.

$$Correcto\ ampliado = \frac{N_{correcto} + N_{error\ leve}}{N_{total}} \times 100$$

Esta métrica permite valorar descripciones que, aunque no son perfectas, mantienen una utilidad morfológico-descriptiva razonable.

J. Accuracy por atributo morfológico

La accuracy por atributo evalúa la proporción de casos en los que un atributo morfológico específico fue descrito correctamente.

$$Accuracy(a) = \frac{N_{aciertos}(a)}{N_{evaluables}(a)} \times 100$$

donde representa un atributo concreto, como tamaño celular, cromatina, citoplasma o granulación; $N_{aciertos}(a)$ es el número de descripciones correctas para ese atributo; y $N_{evaluables}(a)$ es el número de muestras en las que dicho atributo podía evaluarse.

K. Concordancia entre evaluadores automáticos

Para estimar la robustez de la auditoría automática, se compararon las categorías asignadas por Gemini-3-flash-preview y Qwen2.5-VL sobre una muestra estratificada.

La concordancia observada se definió como:

$$P_o = \frac{N_{acuerdos}}{N_{total}}$$

donde $N_{acuerdos}$ es el número de muestras en las que ambos auditores asignaron la misma categoría y N_{total} es el número total de muestras evaluadas por ambos modelos.

Para Cohen's kappa:

$$\kappa = \frac{P_o - P_e}{1 - P_e}$$

donde P_o es la concordancia observada y P_e es la concordancia esperada por azar. Valores de K cercanos a 1 indican alta concordancia, valores cercanos a 0 indican concordancia similar a lazar y valores negativos indican desacuerdo superior al esperado por azar.

Las métricas anteriores se interpretaron de forma complementaria. Las métricas NLP permiten evaluar similitud textual y semántica, pero no garantizan por sí solas la precisión morfológica. Por este motivo, la evaluación principal del trabajo incorporó auditoría automática multimodal y análisis por atributos, que permiten valorar con mayor detalle la correspondencia entre imagen, descripción y rasgos hematológicos relevantes.

Anexo 3. Prompt de evaluación automática

Este anexo presenta la plantilla de evaluación utilizada para la auditoría automática de las descripciones generadas por los distintos modelos. La plantilla incorpora la clase celular real, la descripción objetivo y la *caption* generada, permitiendo a Gemini-3-flash-preview asignar categorías de calidad, detectar errores morfológicos y valorar la adecuación descriptiva de cada instancia.

La estructura mostrada corresponde a un ejemplo representativo del protocolo empleado durante la evaluación automática de las descripciones generadas en los distintos experimentos realizados.

Prompt utilizado

Analiza las descripciones de una célula sanguínea y clasifica los errores.

Clase real: eosinophil

Target: a eosinophil cell with intermediate size, bilobed nucleus, moderate nucleocytoplasmic ratio.

BLIP base: an image of a blood cell, showing the red and white cells

BLIP v1: a eosinophil cell with intermediate size, low nucleocytoplasmic ratio.

BLIP v2: a eosinophil cell with intermediate size, bilobed nucleus, moderate nucleocytoplasmic ratio.

Formato de salida:

- error_base
- error_v1
- error_v2
- explicacion